

Introducción a la Ciencia de Datos

Maestría en Probabilidad y Estadística

Dr. Marco Antonio Aquino López

Centro de Investigación en Matemáticas

Agosto–Diciembre 2025



Clasificación vs. Regresión

Problemas de Clasificación

- Variable respuesta es **categórica** (p. ej., spam / no spam).
- Objetivo: asignar cada observación a una clase.

Problemas de Regresión

- Variable respuesta es **continua** (p. ej., precio de una casa).
- Objetivo: predecir un valor numérico dado un conjunto de covariables.

¿Por qué estudiar regresión?

- La regresión es una de las herramientas más utilizadas en estadística aplicada.
- Permite no solo **predecir**, sino también **interpretar relaciones** entre variables.
- Es la base de muchos métodos más avanzados: desde modelos de series de tiempo hasta deep learning.
- Sirve como contraste natural con la clasificación:

En lugar de decidir una etiqueta, cuantificamos un resultado.

¿Por qué regresión lineal?

Motivación

- Muchos problemas científicos y aplicados buscan entender la **relación entre variables**.
- Ejemplos:
 - ▶ ¿Cómo influye el tiempo de estudio en el desempeño académico?
 - ▶ ¿Cómo cambia el consumo eléctrico con la temperatura?
 - ▶ ¿Qué factores explican el precio de una vivienda?
- La regresión lineal es el **modelo más simple y ampliamente utilizado** para cuantificar estas relaciones.
- Sirve como **punto de partida** para modelos más sofisticados (generalizados, no lineales, bayesianos).

De la intuición al modelo

Idea básica

Aproximamos la relación entre X e Y con una **función lineal**:

$$Y \approx \beta_0 + \beta_1 X$$

- El parámetro β_0 representa el **intercepto**.
- El parámetro β_1 mide la **pendiente** o efecto de X sobre Y .
- La diferencia entre el valor observado y el predicho es el **error**.

Modelo de regresión lineal

Definición

Dados datos $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$ con $y_i \in \mathbb{R}$, se asume

$$y_i = \mathbf{x}_i^\top \beta + \varepsilon_i,$$

donde $\beta \in \mathbb{R}^p$ es desconocido y ε_i son errores aleatorios.

Planteamiento del problema

- Queremos estimar el vector de parámetros β en el modelo:

$$y = X\beta + \varepsilon$$

- La idea central: encontrar $\hat{\beta}$ que haga que las predicciones

$$\hat{y} = X\hat{\beta}$$

estén lo más cerca posible de los datos observados y .

- ¿Cómo medimos la cercanía? Usando la suma de cuadrados de los errores.

Función de pérdida: suma de cuadrados

Criterio de mínimos cuadrados

$$L(\beta) = \|y - X\beta\|^2 = (y - X\beta)^T(y - X\beta)$$

- Buscamos $\hat{\beta}$ que minimice $L(\beta)$.
- Este es un problema de optimización cuadrática en β .
- La solución se obtiene derivando y resolviendo la ecuación normal.

Derivación del estimador OLS

$$\begin{aligned}L(\beta) &= (y - X\beta)^T (y - X\beta) \\&= y^T y - 2\beta^T X^T y + \beta^T X^T X\beta\end{aligned}$$

Derivada respecto a β

$$\frac{\partial L}{\partial \beta} = -2X^T y + 2X^T X\beta$$

$$\Rightarrow X^T X\hat{\beta} = X^T y$$

Solución y geometría

Estimador de mínimos cuadrados

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

- $\hat{y} = X\hat{\beta}$ es la proyección ortogonal de y sobre el subespacio columna de X .
- Los residuos $\hat{\varepsilon} = y - \hat{y}$ son ortogonales a todas las columnas de X .

$$X^T \hat{\varepsilon} = 0$$

el subespacio columna de X .

- Se interpreta como **minimizar el error cuadrático** en el espacio de hipótesis lineales, lo que conecta regresión lineal con redes neuronales lineales.
- Nos permite construir inferencias, ya que la ortogonalidad garantiza la independencia entre estimadores y errores bajo supuestos clásicos.

¿Qué necesitamos para confiar en OLS?

- El estimador OLS siempre existe (si X tiene rango completo).
- Pero sus propiedades (insesgamiento, mínima varianza) dependen de ciertos supuestos.
- Estos supuestos se llaman **supuestos de Gauss–Markov**.
- Vamos a construirlos uno por uno.

Supuesto 1: Modelo correctamente especificado

$$y = X\beta + \varepsilon$$

- Asumimos que la relación es **lineal en parámetros**.
- Si el modelo es incorrecto (por ejemplo, falta una variable relevante), OLS ya no es insesgado.
- Este es el “piso” sobre el cual construimos los demás supuestos.

Supuesto 2: Rango completo de X

No colinealidad

Ninguna columna de X es combinación lineal exacta de las demás.

- Garantiza que $(X^\top X)^{-1}$ existe.
- Sin este supuesto, el problema de OLS no tiene solución única.
- En la práctica: cuidado con multicolinealidad (aunque sea aproximada).

Supuestos 3–5: Errores

- ① $E[\varepsilon_i] = 0$
⇒ asegura que OLS es insesgado.
- ② $Var(\varepsilon_i) = \sigma^2$ constante (homocedasticidad)
⇒ permite calcular varianzas de $\hat{\beta}$ y compararlas.
- ③ $Cov(\varepsilon_i, \varepsilon_j) = 0$ para $i \neq j$
⇒ evita correlación que inflaría o reduciría la varianza.

Idea: los errores deben ser “ruido puro”, sin patrón sistemático.

Supuesto 6: Predictores independientes del error

- Se asume que X es fijo (diseño experimental) o que $X \perp \varepsilon$ (en muestreo).
- Así, la variabilidad de y se explica sólo por la parte lineal más el error.
- Sin este supuesto, los predictores podrían estar “contaminados” y OLS perdería insesgamiento.

Teorema de Gauss–Markov

Enunciado

Bajo los supuestos clásicos:

- Modelo lineal en parámetros: $y = X\beta + \varepsilon$.
- $E[\varepsilon] = 0$, $Var(\varepsilon) = \sigma^2 I$.
- X de rango completo.

Entonces, el estimador OLS

$$\hat{\beta} = (X^\top X)^{-1} X^\top y$$

es el **mejor estimador lineal insesgado (BLUE)**: cualquier otro estimador lineal insesgado de β tiene varianza mayor o igual.

Demostración: idea general

- ① Mostrar que $\hat{\beta}$ es insesgado: $E[\hat{\beta}] = \beta$.
- ② Calcular su varianza: $Var(\hat{\beta}) = \sigma^2(X^\top X)^{-1}$.
- ③ Considerar cualquier otro estimador lineal insesgado:

$$\tilde{\beta} = Cy, \quad CX = I_p.$$

- ④ Probar que $Var(\tilde{\beta}) - Var(\hat{\beta})$ es semidefinida positiva.

Paso 1: Insesgamiento de OLS

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

Sustituyendo $\mathbf{y} = \mathbf{X}\beta + \varepsilon$:

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{X}\beta + \varepsilon) = \beta + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \varepsilon$$

Entonces:

$$E[\hat{\beta}] = \beta + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top E[\varepsilon] = \beta$$

Conclusión: OLS es insesgado.

Paso 2: Varianza de OLS

Como $\hat{\beta} = \beta + (X^\top X)^{-1} X^\top \varepsilon$:

$$Var(\hat{\beta}) = (X^\top X)^{-1} X^\top Var(\varepsilon) X (X^\top X)^{-1}$$

Dado que $Var(\varepsilon) = \sigma^2 I$:

$$Var(\hat{\beta}) = \sigma^2 (X^\top X)^{-1}$$

Modelo Bayesiano: Motivación

- La regresión lineal clásica asume parámetros fijos desconocidos.
- En el enfoque bayesiano, los parámetros son **variables aleatorias**.
- Esto permite:
 - ▶ Incorporar información previa (*priors*).
 - ▶ Obtener distribuciones posteriores que cuantifican la incertidumbre.

Modelo Lineal

Planteamiento

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_n)$$

- \mathbf{y} : vector $n \times 1$ de respuestas.
- \mathbf{X} : matriz de diseño $n \times p$.
- $\boldsymbol{\beta}$: vector $p \times 1$ de coeficientes.
- σ^2 : varianza común de los errores.

Enfoque Bayesiano

- Ahora tratamos β y σ^2 como aleatorios.
- Teorema de Bayes:

$$p(\beta, \sigma^2 | \mathbf{y}, \mathbf{X}) \propto p(\mathbf{y} | \mathbf{X}, \beta, \sigma^2) p(\beta, \sigma^2)$$

Prior Conjugado

Normal-Inversa Gamma

$$\boldsymbol{\beta} \mid \sigma^2 \sim \mathcal{N}(\boldsymbol{\beta}_0, \sigma^2 V_0), \quad \sigma^2 \sim \text{Inv-Gamma}(a_0, b_0)$$

- Familia conjugada que garantiza posterior con la misma forma.

Posterior Conjugada

Distribuciones posteriores

$$\boldsymbol{\beta} \mid \sigma^2, \mathbf{y} \sim \mathcal{N}(\boldsymbol{\beta}_n, \sigma^2 V_n)$$

$$\sigma^2 \mid \mathbf{y} \sim \text{Inv-Gamma}(a_n, b_n)$$

Posterior Conjugada

Distribuciones posteriores

$$\boldsymbol{\beta} \mid \sigma^2, \mathbf{y} \sim \mathcal{N}(\boldsymbol{\beta}_n, \sigma^2 V_n)$$

$$\sigma^2 \mid \mathbf{y} \sim \text{Inv-Gamma}(a_n, b_n)$$

Parámetros actualizados

$$V_n = \left(V_0^{-1} + X^\top X \right)^{-1}, \quad \boldsymbol{\beta}_n = V_n \left(V_0^{-1} \boldsymbol{\beta}_0 + X^\top \mathbf{y} \right)$$

$$a_n = a_0 + \frac{n}{2}, \quad b_n = b_0 + \frac{1}{2} (\mathbf{y}^\top \mathbf{y} + \boldsymbol{\beta}_0^\top V_0^{-1} \boldsymbol{\beta}_0 - \boldsymbol{\beta}_n^\top V_n^{-1} \boldsymbol{\beta}_n)$$

Propiedades de la Posterior

- **Distribución conjunta:** (β, σ^2) sigue una forma conjugada tractable.
- **Marginal de β :** una distribución t multivariada.
- **Marginal de σ^2 :** una Inversa-Gamma.
- Refleja la combinación de evidencia previa y datos observados.

¿Por qué una Distribución Predictiva?

- La posterior nos dice lo que creemos de los **parámetros**.
- Pero en la práctica, muchas veces lo que queremos es:
 - ▶ Predecir una nueva observación y_* .
 - ▶ Evaluar el ajuste del modelo frente a datos no observados.
 - ▶ Construir intervalos de predicción con interpretación probabilística.

¿Por qué una Distribución Predictiva?

- La posterior nos dice lo que creemos de los **parámetros**.
- Pero en la práctica, muchas veces lo que queremos es:
 - ▶ Predecir una nueva observación y_* .
 - ▶ Evaluar el ajuste del modelo frente a datos no observados.
 - ▶ Construir intervalos de predicción con interpretación probabilística.
- La **distribución predictiva** combina:
 - ▶ La incertidumbre en los parámetros (β, σ^2) .
 - ▶ La variabilidad inherente de los errores.

¿Por qué una Distribución Predictiva?

- La posterior nos dice lo que creemos de los **parámetros**.
- Pero en la práctica, muchas veces lo que queremos es:
 - ▶ Predecir una nueva observación y_* .
 - ▶ Evaluar el ajuste del modelo frente a datos no observados.
 - ▶ Construir intervalos de predicción con interpretación probabilística.
- La **distribución predictiva** combina:
 - ▶ La incertidumbre en los parámetros (β, σ^2) .
 - ▶ La variabilidad inherente de los errores.
- Resultado: una distribución completa para y_* que refleja toda la incertidumbre disponible.

Distribución Predictiva

- Definición general:

$$p(y_* \mid \mathbf{y}, \mathcal{X}, \mathbf{x}_*) = \int \int p(y_* \mid \boldsymbol{\beta}, \sigma^2, \mathbf{x}_*) \, p(\boldsymbol{\beta}, \sigma^2 \mid \mathbf{y}, \mathcal{X}) \, d\boldsymbol{\beta} \, d\sigma^2$$

- Dos integrales:

- ① Primero sobre $\boldsymbol{\beta}$.
- ② Luego sobre σ^2 .

Paso 1: Integración sobre β

$$p(y_* \mid \sigma^2, \mathbf{y}, X, \mathbf{x}_*) = \int \int p(y_* \mid \boldsymbol{\beta}, \sigma^2, \mathbf{x}_*) p(\boldsymbol{\beta} \mid \sigma^2, \mathbf{y}, X) d\boldsymbol{\beta}$$

Paso 1: Integración sobre β

$$p(y_* \mid \sigma^2, \mathbf{y}, \mathcal{X}, \mathbf{x}_*) = \int \int p(y_* \mid \boldsymbol{\beta}, \sigma^2, \mathbf{x}_*) p(\boldsymbol{\beta} \mid \sigma^2, \mathbf{y}, \mathcal{X}) d\boldsymbol{\beta}$$

Resultado

$$y_* \mid \sigma^2, \mathbf{y}, \mathcal{X}, \mathbf{x}_* \sim \mathcal{N}\left(\mathbf{x}_*^\top \boldsymbol{\beta}_n, \ \sigma^2(1 + \mathbf{x}_*^\top V_n \mathbf{x}_*)\right)$$

Paso 2: Integración sobre σ^2

$$p(y_* \mid \mathbf{y}, \mathcal{X}, \mathbf{x}_*) = \int p(y_* \mid \sigma^2, \mathbf{y}, \mathcal{X}, \mathbf{x}_*) p(\sigma^2 \mid \mathbf{y}, \mathcal{X}) d\sigma^2$$

Paso 2: Integración sobre σ^2

$$p(y_* \mid \mathbf{y}, \mathcal{X}, \mathbf{x}_*) = \int p(y_* \mid \sigma^2, \mathbf{y}, \mathcal{X}, \mathbf{x}_*) p(\sigma^2 \mid \mathbf{y}, \mathcal{X}) d\sigma^2$$

- Sabemos que:

$$\sigma^2 \mid \mathbf{y}, \mathcal{X} \sim \text{Inv-Gamma}(a_n, b_n)$$

- La mezcla Normal–Inv-Gamma es conocida: produce una distribución t .

Resultado Final

Distribución predictiva

$$y_* \mid \mathbf{y}, \mathcal{X}, \mathbf{x}_* \sim t_{2a_n} \left(\mathbf{x}_*^\top \boldsymbol{\beta}_n, \frac{b_n}{a_n} \left(1 + \mathbf{x}_*^\top V_n \mathbf{x}_* \right) \right)$$

- Grados de libertad: $2a_n$.
- Media: $\mathbf{x}_*^\top \boldsymbol{\beta}_n$.
- Varianza escalada: $\frac{b_n}{a_n} \left(1 + \mathbf{x}_*^\top V_n \mathbf{x}_* \right)$.

Predicción Bayesiana

Nueva observación \mathbf{x}_*

$$y_* \mid \mathbf{y}, \mathbf{X}, \mathbf{x}_* \sim t_{2a_n} \left(\mathbf{x}_*^\top \boldsymbol{\beta}_n, \frac{b_n}{a_n} \left(1 + \mathbf{x}_*^\top V_n \mathbf{x}_* \right) \right)$$

- La distribución predictiva es una t de Student.
- Incorpora tanto la incertidumbre de parámetros como la varianza residual.

Supuestos de la Regresión Lineal Bayesiana

- **Linealidad:** la relación entre covariables y respuesta se modela como

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}.$$

- **Normalidad de los errores:**

$$\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_n).$$

- **Independencia:** los errores son independientes entre observaciones.
- **Varianza constante:** homocedasticidad, la misma σ^2 para todos los y_i .
- **Especificación del prior:** se asume una distribución previa para $(\boldsymbol{\beta}, \sigma^2)$, típicamente Normal–Inversa Gamma.
- **Matriz de diseño X conocida y fija:** no aleatoria en el análisis.

Clásica vs. Bayesiana (I)

Aspecto	Regresión Clásica	Regresión Bayesiana
Tratamiento de parámetros	Fijos pero desconocidos	Variables aleatorias con distribución a priori
Resultado principal	Estimadores puntuales e IC basados en asintótica	Distribuciones posteriores e intervalos creíbles con interpretación probabilística
Uso de información previa	No incluye (salvo restricciones)	Incorpora priors que reflejan conocimiento experto

Clásica vs. Bayesiana (II)

Aspecto	Regresión Clásica	Regresión Bayesiana
Predicción	Basada en estimadores puntuales, IC aproximados	Predictiva completa que incluye incertidumbre de parámetros y ruido
Interpretación	Simple, estándar en estadística clásica	Más rica, pero requiere mayor formación conceptual
Costo computacional	Bajo (soluciones analíticas cerradas)	Puede ser alto (inferencia numérica/MCMC si no hay conjugación)
Flexibilidad	Limitada a extensiones clásicas	Extensible a modelos jerárquicos, no lineales, mixtos

Conexiones con OLS y Ridge

- **OLS como caso límite:** Si $\Sigma_0^{-1} \rightarrow 0$ y $a_0, b_0 \rightarrow 0$ (prior débil / no informativo), entonces

$$\beta_n \rightarrow (X^\top X)^{-1} X^\top y \quad (\text{Mínimos Cuadrados Ordinarios}).$$

Conexiones con OLS y Ridge

- **OLS como caso límite:** Si $\Sigma_0^{-1} \rightarrow 0$ y $a_0, b_0 \rightarrow 0$ (prior débil / no informativo), entonces

$$\boldsymbol{\beta}_n \rightarrow (X^\top X)^{-1} X^\top y \quad (\text{Mínimos Cuadrados Ordinarios}).$$

- **Ridge como MAP:** Con prior gaussiano isotrópico

$$\boldsymbol{\beta} \mid \sigma^2 \sim \mathcal{N}(0, \sigma^2 \lambda^{-1} I),$$

el *modo a posteriori* satisface

$$\hat{\boldsymbol{\beta}}_{\text{MAP}} = \arg \min_{\boldsymbol{\beta}} \|y - X\boldsymbol{\beta}\|^2 + \lambda \|\boldsymbol{\beta}\|^2,$$

que coincide con la **regresión Ridge**.

Regresión Ridge: Motivación

- En Mínimos Cuadrados Ordinarios (OLS), los estimadores pueden tener alta varianza si:
 - ▶ Las variables están fuertemente correlacionadas.
 - ▶ El número de predictores p es grande comparado con n .
- Ridge busca reducir la varianza mediante una **penalización cuadrática**.
- **El parámetro λ (lambda):**
 - ▶ Controla la **fuerza de la penalización** en los coeficientes
 - ▶ $\lambda \geq 0$ (siempre un valor no negativo)

Regresión Ridge en Bayes

- Enfoque bayesiano: asumimos un prior normal isotrópico sobre los coeficientes:

$$\beta \mid \sigma^2 \sim \mathcal{N}(0, \sigma^2 \lambda^{-1} I).$$

Regresión Ridge en Bayes

- Enfoque bayesiano: asumimos un prior normal isotrópico sobre los coeficientes:

$$\beta \mid \sigma^2 \sim \mathcal{N}(0, \sigma^2 \lambda^{-1} I).$$

- La función de densidad es

$$p(\beta \mid \sigma^2) \propto \exp\left(-\frac{\lambda}{2\sigma^2} \|\beta\|^2\right).$$

- Combinada con la verosimilitud gaussiana, el **estimador Maximo a Posterior (MAP)** es:

$$\hat{\beta}_{MAP} = \arg \min_{\beta} \|y - X\beta\|^2 + \lambda \|\beta\|^2.$$

Interpretación Bayesiana de Ridge

- El prior normal isotrópico refleja la creencia de que los coeficientes tienden a estar **cerca de cero**, pero sin forzarlos exactamente.
 - La penalización λ controla el grado de contracción:
 - **El parámetro λ (lambda):**
 - ▶ Controla la **fuerza de la penalización** en los coeficientes
 - ▶ $\lambda \geq 0$ (siempre un valor no negativo)
 - ▶ Cuando $\lambda = 0$: recuperamos el modelo OLS estándar
 - ▶ Cuando $\lambda \rightarrow \infty$: todos los coeficientes se reducen hacia cero
 - ▶ Valores intermedios de λ encuentran equilibrio entre sesgo y varianza
 - La regresión Ridge es equivalente a imponer un prior gaussiano y tomar el MAP.
 - Extiende OLS reduciendo varianza a cambio de un sesgo controlado (*bias–variance tradeoff*).
- ¿Cómo elegir λ ?** Normalmente mediante validación cruzada.

Conexiones con Lasso

- **Lasso como MAP:** Si asumimos que los coeficientes siguen una distribución Laplace:

$$\beta_j \sim \text{Laplace}(0, \tau),$$

entonces obtenemos:

$$\hat{\beta}_{MAP} = \arg \min_{\beta} \|y - X\beta\|^2 + \lambda \|\beta\|_1,$$

que es exactamente la **regresión Lasso** [3].

- **¿Qué hace el parámetro λ aquí?**

- ▶ Controla el **nivel de penalización** en los coeficientes
- ▶ λ grande: coeficientes más pequeños, más variables se hacen cero
- ▶ λ pequeño: coeficientes más grandes, menos variables se eliminan

- **Características clave:**

- ▶ Penaliza la suma de valores absolutos (no cuadrados)
- ▶ *Sparsity*: produce coeficientes exactamente cero (elimina variables)
- ▶ **En palabras simples:** Lasso no solo reduce coeficientes, sino que elimina variables innecesarias

Regresión Lasso: Motivación

- **Problema con Ridge:** Reduce coeficientes pero nunca los hace exactamente cero.
- **Solución con Lasso:** Puede eliminar variables completamente.
- **¿Cuándo usar Lasso?**
 - ▶ Cuando tenemos muchas variables y queremos identificar las más importantes
 - ▶ Cuando buscamos modelos más simples y fáciles de interpretar
 - ▶ Cuando creemos que solo algunas variables realmente importan
- **La fórmula de Lasso:**

$$\hat{\beta}^{\text{Lasso}} = \arg \min_{\beta} \|y - X\beta\|^2 + \lambda \|\beta\|_1,$$

donde $\|\beta\|_1 = \sum_j |\beta_j|$ (suma de valores absolutos).

- **El rol de λ :**
 - ▶ Controla cuántas variables se eliminan
 - ▶ λ muy grande: casi todos los coeficientes son cero
 - ▶ λ muy pequeño: casi como OLS tradicional

Regresión Lasso en Bayes

- **Enfoque bayesiano:** Asumimos que cada coeficiente sigue una distribución Laplace:

$$\beta_j \sim \text{Laplace}(0, \tau), \quad p(\beta_j) \propto \exp\left(-\frac{|\beta_j|}{\tau}\right).$$

- **¿Por qué Laplace?**

- ▶ Esta distribución favorece que muchos coeficientes sean exactamente cero
- ▶ Es como decir: "creemos que muchas variables probablemente no son importantes"

- **Resultado importante:** El máximo a posteriori (MAP) bajo este prior es:

$$\hat{\beta}_{MAP} = \arg \min_{\beta} \|y - X\beta\|^2 + \lambda \|\beta\|_1.$$

- **Conclusión:** Lasso = solución bayesiana con distribuciones Laplace

- **Relación λ - τ :**

- ▶ $\lambda = \frac{1}{\tau}$ (parámetros inversamente relacionados)
- ▶ λ grande $\Leftrightarrow \tau$ pequeño: más penalización, más coeficientes cero

Interpretación Bayesiana de Lasso

- **¿Por qué Lasso elimina variables?**

- ▶ La distribución Laplace tiene "picos" en cero
- ▶ Esto hace que sea más probable que los coeficientes sean exactamente cero
- ▶ **Analogía:** Es como tener un "prejuicio" de que muchas variables son innecesarias

- **Ventajas de Lasso:**

- ▶ **Selección automática:** Elige qué variables incluir y cuáles eliminar
- ▶ **Modelos simples:** Produce modelos más fáciles de interpretar
- ▶ **Elimina redundancias:** Ayuda cuando hay variables correlacionadas

- **Limitaciones:**

- ▶ Si varias variables están muy correlacionadas, Lasso puede elegir arbitrariamente una
- ▶ Puede ser inestable con datos muy correlacionados
- ▶ λ debe elegirse cuidadosamente (usualmente por validación cruzada)

g-prior de Zellner: Motivación

- **Problema con Ridge y Lasso:**

- ▶ Tratan todos los coeficientes como igualmente importantes
- ▶ No consideran cómo se relacionan las variables entre sí
- ▶ **Analogía:** Es como dar el mismo peso a todas las materias sin importar su dificultad

- **Solución del g-prior:**

- ▶ Usa la información de los datos mismos para definir el prior
- ▶ Considera que algunas direcciones en los datos son más importantes que otras
- ▶ **En palabras simples:** Ajusta el prior según la "geometría" de tus datos

- **Objetivo:** Balancear "inteligentemente" entre lo que creemos antes de ver los datos y lo que los datos nos dicen

g-prior de Zellner: La Fórmula

- **La fórmula clave:**

$$\boldsymbol{\beta} \mid \sigma^2 \sim \mathcal{N}\left(0, g\sigma^2(X^\top X)^{-1}\right).$$

- **¿Qué significa cada parte?**

- ▶ $\boldsymbol{\beta}$: coeficientes del modelo
- ▶ σ^2 : varianza del error
- ▶ $(X^\top X)^{-1}$: información sobre cómo se relacionan las variables
- ▶ g : **parámetro clave** que controla la fuerza del prior

- **El parámetro g explicado:**

- ▶ Controla cuánto "confiamos" en nuestro prior vs. en los datos
- ▶ g pequeño: más confianza en el prior (coeficientes cerca de cero)
- ▶ g grande: más confianza en los datos (coeficientes más libres)
- ▶ $g \rightarrow \infty$: recuperamos OLS tradicional

¿Por qué el g-prior es "inteligente" ?

- **Considera las correlaciones:**

- ▶ Si dos variables están correlacionadas, el g-prior lo tiene en cuenta
- ▶ No trata cada variable como si fuera independiente de las demás

- **Ajusta por la escala:**

- ▶ Automáticamente considera que algunas variables tienen más varianza que otras
- ▶ No necesitamos estandarizar las variables manualmente

- **Ejemplo intuitivo:**

- ▶ Imagina predecir el precio de una casa
- ▶ El g-prior reconoce que "área" y "número de habitaciones" están relacionadas
- ▶ No las trata como variables completamente separadas

- **Ventaja práctica:** Cálculos más eficientes y resultados más estables

Aplicaciones y Consideraciones Prácticas

- **Selección de modelos:**

- ▶ Diferentes valores de g nos llevan a preferir modelos distintos
- ▶ Podemos comparar qué tan bueno es cada modelo usando factores de Bayes

- **Valores típicos de g :**

- ▶ $g = n$ (tamaño de muestra): "prior de información unitaria"
- ▶ $g = p^2$ o $g = n/p^2$: otras opciones comunes
- ▶ En la práctica: probamos varios valores y elegimos el mejor

- **Ventajas:**

- ▶ Muy bueno para comparar modelos
- ▶ Considera la estructura de correlación de los datos
- ▶ Cálculos relativamente simples

- **Precauciones:**

- ▶ La elección de g es importante
- ▶ Puede ser sensible si hay variables muy correlacionadas
- ▶ Necesitamos que $X^T X$ sea invertible

Referencias I



Gauss, C. F. (1821).

Teoría de la combinación de observaciones sujeta a los errores mínimos

[Título original en latín: *Theoria combinationis observationum erroribus minimis obnoxiae*].

Commentationes Societatis Regiae Scientiarum Gottingensis Recentiores, Vol. V.



Hoerl, A. E., & Kennard, R. W. (1970).

Ridge regression: Biased estimation for nonorthogonal problems.

Technometrics, 12(1), 55–67.



Tibshirani, R. (1996).

Regression shrinkage and selection via the Lasso.

Journal of the Royal Statistical Society: Series B, 58(1), 267–288.

Referencias II



Zellner, A. (1986).

On assessing prior distributions and Bayesian regression analysis with g-prior distributions.
In *Bayesian Inference and Decision Techniques*, pp. 233–243.

Referencias adicionales I

-  Bishop, C. M. (2006).
Pattern Recognition and Machine Learning.
Springer. (**Cap. 3:** Regresión lineal, conexión Bayes–MAP con Ridge y Lasso)
-  Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D., Vehtari, A., & Rubin, D. (2013).
Bayesian Data Analysis (3rd ed.).
Chapman & Hall/CRC. (**Cap. 14:** Modelos lineales bayesianos, priors conjugados y g-priors)
-  Hastie, T., Tibshirani, R., & Friedman, J. (2009).
The Elements of Statistical Learning (2nd ed.).
Springer. (**Cap. 3:** Regularización, Ridge y Lasso, desde el punto de vista clásico)
-  Murphy, K. P. (2023).
Probabilistic Machine Learning: Advanced Topics.
MIT Press. (**Cap. 12:** Bayesian linear regression, priors y conexión con regularización)

Motivación: Cuando la respuesta es sí/no

- **Ejemplos del mundo real:**

- ▶ ¿Aprobará el examen? Sí/No
- ▶ ¿Tendrá la enfermedad? Sí/No

- **El problema fundamental:**

- ▶ Regresión lineal: $y = \beta_0 + \beta_1 x + \epsilon$
- ▶ Puede predecir: $y = 1,2$ o $y = -0,3$
- ▶ **¡Esto no tiene sentido como probabilidad!**

Recordatorio importante

En problemas de clasificación binaria, no modelamos la categoría directamente, sino la **probabilidad** de pertenecer a cada categoría.

Construyendo el modelo: La necesidad de una transformación

- **Problema central:** Necesitamos conectar el predictor lineal $\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$ con una probabilidad $\pi_i = P(y_i = 1)$.
- **¿Por qué no usar directamente?** $\pi_i = \mathbf{x}_i^\top \boldsymbol{\beta}$
 - ▶ Podría dar $\pi_i < 0$ o $\pi_i > 1$
 - ▶ **¡Las probabilidades deben estar entre 0 y 1!**
- **Propuesta natural:** Buscar una función f que:
 - ▶ Transforme cualquier número real a $[0,1]$
 - ▶ Sea creciente (a mayor η_i , mayor probabilidad)
 - ▶ Sea invertible (para poder interpretar)
- **Candidatas comunes:**
 - ▶ Función logística
 - ▶ Función de distribución normal (probit)
 - ▶ Función log-log

Pregunta para reflexionar

¿Qué propiedades debería tener la función ideal para modelar probabilidades?

La función logística: una elección natural

- **Función logística:**

$$f(z) = \frac{1}{1 + e^{-z}} = \frac{e^z}{1 + e^z}$$

- **Propiedades clave:**

- ▶ Cuando $z \rightarrow -\infty$, $f(z) \rightarrow 0$
- ▶ Cuando $z \rightarrow +\infty$, $f(z) \rightarrow 1$
- ▶ $f(0) = 0,5$ (punto medio)
- ▶ Forma de "S" suave (sigmoide)

- **Aplicando a nuestro modelo:**

$$\pi_i = P(y_i = 1 \mid x_i) = \frac{1}{1 + e^{-x_i^\top \beta}}$$

- **Interpretación:** La probabilidad depende del predictor lineal a través de esta transformación

Visualización

La curva logística transforma valores entre $-\infty$ y $+\infty$ al rango $[0,1]$ de manera suave.

El logit: la transformación inversa

- **Problema:** ¿Cómo recuperar la relación lineal?
- **Despejemos:**

$$\pi_i = \frac{1}{1 + e^{-x_i^\top \beta}}$$
$$1 - \pi_i = \frac{e^{-x_i^\top \beta}}{1 + e^{-x_i^\top \beta}}$$
$$\frac{\pi_i}{1 - \pi_i} = e^{x_i^\top \beta}$$

- **Definición del logit:**

$$\text{logit}(\pi_i) = \log\left(\frac{\pi_i}{1 - \pi_i}\right) = x_i^\top \beta$$

- **Interpretación:**

- ▶ $\frac{\pi_i}{1 - \pi_i} = \text{odds}$ (razón de probabilidades)
- ▶ $\log(\text{odds}) = \text{log-odds}$
- ▶ ¡El logit nos devuelve la estructura lineal!

Modelo logístico y función logit

Definición

Para variable binaria $y_i \in \{0, 1\}$, la regresión logística modela la probabilidad $p_i = \Pr(y_i = 1)$ mediante

$$\text{logit}(p_i) = \log \left(\frac{p_i}{1 - p_i} \right) = \mathbf{x}_i^\top \boldsymbol{\beta}.$$

La inversa logística transforma de regreso a la escala de probabilidades: $p_i = \frac{e^{\mathbf{x}_i^\top \boldsymbol{\beta}}}{1 + e^{\mathbf{x}_i^\top \boldsymbol{\beta}}}.$

- Los coeficientes $\boldsymbol{\beta}$ representan cambios en los *log-odds*: un incremento en x_j multiplica las odds por e^{β_j} .
- La relación entre probabilidad y predictor es no lineal; los efectos se moderan en los extremos de la curva sigmoidal.

Estimación por máxima verosimilitud

Log-verosimilitud

La verosimilitud para datos $\{y_i\}$ bajo independencia es

$$\ell(\beta) = \sum_{i=1}^n [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)].$$

No existe solución analítica para maximizar $\ell(\beta)$; se utiliza el método de Newton–Raphson o iterativamente reponderación de mínimos cuadrados (IRLS).

- La función de verosimilitud es cóncava; Newton–Raphson converge rápidamente.
- Los errores estándar de $\hat{\beta}$ se obtienen a partir de la matriz de información de Fisher.

De máxima verosimilitud a enfoque bayesiano

- **Enfoque clásico (MLE):**

- ▶ Encontramos $\hat{\beta}$ que maximiza la verosimilitud
- ▶ Respuesta única sin cuantificar incertidumbre

- **Problema:** ¿Y si queremos incorporar conocimiento previo o medir incertidumbre?

- **Solución bayesiana:** Tratamos β como variable aleatoria

$$\underbrace{p(\beta | y, X)}_{\text{posterior}} \propto \underbrace{\prod_{i=1}^n \pi_i^{y_i} (1 - \pi_i)^{1-y_i}}_{\text{verosimilitud}} \times \underbrace{p(\beta)}_{\text{prior}}$$

- **Ventajas:**

- ▶ Incorpora conocimiento previo mediante el prior
- ▶ Cuantifica incertidumbre completa sobre los parámetros
- ▶ Predicciones más robustas

El corazón del enfoque bayesiano

Actualizamos nuestro conocimiento sobre β combinando lo que sabíamos antes (prior) con lo que nos dicen los datos (verosimilitud).

¿Cómo elegir nuestros priors?

- **Prior Normal (Gaussiano):**

$$\beta \sim \mathcal{N}(0, \sigma^2 I)$$

- ▶ **Equivalente frecuentista:** Regularización Ridge
- ▶ **Uso:** Cuando queremos coeficientes pequeños pero no cero

- **Prior Laplace (Doble Exponencial):**

$$\beta_j \sim \text{Laplace}(0, \tau)$$

- ▶ **Equivalente frecuentista:** Regularización Lasso
- ▶ **Uso:** Para selección automática de variables

- **Priors informativos:** Cuando tenemos conocimiento experto específico

Reto computacional

A diferencia de la regresión lineal normal, aquí no existe un prior conjugado que simplifique los cálculos.

El desafío computacional y sus soluciones

- **Problema:** La posterior no tiene forma analítica cerrada

$$p(\beta \mid y, X) \propto \left[\prod_{i=1}^n \pi_i^{y_i} (1 - \pi_i)^{1-y_i} \right] \times p(\beta)$$

- **Solución**

MCMC (Monte Carlo vía Cadenas de Markov)

- ▶ Herramientas prácticas: Stan, PyMC, JAGS and T-walk.
- ▶ Computacionalmente costoso

Predicciones bayesianas: Más allá del punto único

- Recordemos: $\pi(z) = \frac{1}{1+e^{-z}}$ (función logística)

- **Enfoque clásico:** Predecimos con $\hat{\beta}_{MLE}$

$$P(y_* = 1 \mid x_*) \approx \pi(x_*^\top \hat{\beta}_{MLE})$$

- **Enfoque bayesiano:** Promediamos sobre toda la incertidumbre

$$P(y_* = 1 \mid x_*, \text{datos}) = \int \pi(x_*^\top \beta) p(\beta \mid \text{datos}) d\beta$$

En la práctica

Usamos software como Stan, Twalk, o JAGS que automatizan estos cálculos complejos.

¿Por qué necesitamos diagnosticar los residuales?

- Al ajustar una regresión lineal con Mínimos Cuadrados, hacemos inferencias sobre los coeficientes β_j :
 - ▶ ¿Son significativamente distintos de 0?
 - ▶ ¿Explican realmente la variación de y ?
- Estas pruebas (t , F , intervalos de confianza) se basan en supuestos sobre los errores:

$$e_i \sim N(0, \sigma^2), \quad \text{independientes y homocedásticos}$$

- **Si los supuestos no se cumplen:**
 - ▶ Los errores estándar pueden estar sesgados.
 - ▶ Los valores t y F pueden ser incorrectos.
 - ▶ La inferencia estadística deja de ser válida.
- **Diagnósticos de residuales** = herramientas para verificar que el modelo es confiable.

Normalidad de los Residuales: Verificación

- Supuesto: $e_i \sim N(0, \sigma^2)$.
- Métodos:
 - ▶ **QQ-plot**: los residuales deberían seguir una línea recta.
 - ▶ **Prueba de Shapiro-Wilk**: hipótesis H_0 : normalidad.

Normalidad de los Residuales: Problemas y Soluciones

- Problema: Si no hay normalidad, las pruebas t y F pierden validez.
- Posibles causas:
 - ▶ Datos con colas pesadas.
 - ▶ Outliers.
- Soluciones:
 - ▶ Transformar la variable (\log , $\sqrt{\cdot}$).

Homocedasticidad: Verificación

- Supuesto: $\text{Var}(e_i) = \sigma^2$ constante.
- Verificación:
 - ▶ Gráfico de residuales vs. valores ajustados.
 - ▶ Residuales deben estar distribuidos aleatoriamente sin patrón.

Homocedasticidad: Problemas y Soluciones

- Problema: heterocedasticidad → errores estándar incorrectos.
- Consecuencia: intervalos y pruebas de hipótesis poco fiables.
- Soluciones:
 - ▶ Transformar y (log, Box-Cox).
 - ▶ Modelar explícitamente la varianza (GLS).

Independencia de Residuales: Verificación

- Supuesto: no hay correlación entre residuales.
- Importante en series de tiempo.
- Método:

- ▶ **Prueba Durbin-Watson:**

$$DW = \frac{\sum(e_i - e_{i-1})^2}{\sum e_i^2}$$

- ▶ Valores cercanos a 2 indican independencia.

Independencia de Residuales: Problemas y Soluciones

- Problema: autocorrelación \Rightarrow subestimación de incertidumbre.
- Consecuencias: estadísticos t y F inflados.
- Soluciones:
 - ▶ Incluir rezagos de la variable dependiente o regresores adicionales.
 - ▶ Usar modelos de series de tiempo (AR, ARIMA).

Leverage y Outliers: Verificación

- Algunos puntos tienen gran influencia en el ajuste.
- Diagnósticos:
 - ▶ **Distancia de Cook.**
 - ▶ **Residuales studentizados.**
- Visualización: gráficos de leverage vs. residuales.

Leverage y Outliers: Consecuencias y Soluciones

- Problema: un punto puede distorsionar los coeficientes.
- Consecuencias:
 - ▶ Parámetros sesgados.
 - ▶ Inferencia inválida.
- Soluciones:
 - ▶ Revisar datos y posible error de medición.
 - ▶ Métodos robustos a outliers (regresión robusta).
 - ▶ Considerar transformaciones.

¿Por qué necesitamos evaluar modelos?

- Después de ajustar un modelo (lineal o logístico, clásico o bayesiano) surgen preguntas clave:
 - ▶ ¿Qué tan bien se ajusta a los datos observados?
 - ▶ ¿Predice correctamente nuevos datos?
 - ▶ ¿Es mejor este modelo que otro más simple o más complejo?
- Problema central: **no basta con ajustar un modelo, debemos comparar su desempeño.**
- Distintos enfoques:
 - ▶ **Clásico:** R^2 , pruebas F y t, AIC/BIC, diagnósticos de residuales.
 - ▶ **Bayesiano:** DIC, WAIC, LOO, Posterior Predictive Checks.
- **Objetivo:** Equilibrar entre **ajuste** y **complejidad**, integrando la **incertidumbre** de manera adecuada.

R^2 : Definición e Intuición

- Mide la **proporción de variabilidad** de y explicada por el modelo.

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$$

- Donde:
 - ▶ $SS_{res} = \sum(y_i - \hat{y}_i)^2$ (suma de cuadrados residuales).
 - ▶ $SS_{tot} = \sum(y_i - \bar{y})^2$ (suma total de cuadrados).
- Valores posibles:

$$0 \leq R^2 \leq 1$$

R^2 : Interpretación

- $R^2 = 0$: el modelo no explica nada mejor que la media.
- $R^2 = 1$: el modelo explica toda la variación.
- Ejemplo:
 - ▶ $R^2 = 0,85 \rightarrow$ el 85 % de la variación de y es explicada por el modelo.

Limitaciones

- Siempre aumenta al agregar variables (aunque no sean relevantes).
- No mide calidad predictiva fuera de muestra.

R^2 Ajustado: Motivación

- Problema: R^2 siempre sube al agregar variables.
- Solución: Penalizar por número de predictores p .
- Fórmula:

$$R_{adj}^2 = 1 - \frac{SS_{res}/(n - p - 1)}{SS_{tot}/(n - 1)}$$

R^2 Ajustado: Propiedades

- Puede ser menor que R^2 .
- Útil para comparar modelos con distinto número de predictores.
- Si una nueva variable no mejora lo suficiente el ajuste, R^2_{adj} **disminuye**.

Interpretación

- Mide proporción de varianza explicada ajustada por complejidad.
- Más realista para modelos con muchos predictores.

R^2 Ajustado: Ejemplo

- Modelo 1: $R^2 = 0,80$, $R^2_{adj} = 0,79$.
- Modelo 2 (con 5 variables extra): $R^2 = 0,82$, $R^2_{adj} = 0,75$.
- Conclusión: el Modelo 1 es preferible, pese al mayor R^2 del Modelo 2.

Error Estándar de los Residuales: Definición

- Mide la **desviación promedio** de las predicciones respecto a los valores reales.
- Fórmula:

$$s = \sqrt{\frac{SS_{res}}{n - p - 1}}$$

donde:

- ▶ n = número de observaciones,
- ▶ p = número de predictores.

Error Estándar de los Residuales: Interpretación

- Valores más bajos \Rightarrow mejor ajuste.
- Se expresa en las mismas unidades que y .
- Indica cuánto, en promedio, se desvían las predicciones de los valores observados.

Ejemplo

Si y es ingreso anual en miles de pesos y $s = 2,5$, en promedio el modelo se equivoca $\pm 2,500$ pesos.

Error Estándar de los Residuales: Uso Práctico

- Permite comparar modelos sobre la misma variable.
- Complementa R^2 : dos modelos con igual R^2 pueden tener distinto s .
- Diagnóstico útil cuando la escala de y es relevante.

Prueba Global: Estadístico F

- Objetivo: verificar si el modelo es mejor que usar solo la media de y .
- Hipótesis:

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_p = 0$$

$$H_a : \text{Al menos un } \beta_j \neq 0$$

- Estadístico F:

$$F = \frac{(SS_{tot} - SS_{res})/p}{SS_{res}/(n - p - 1)}$$

Interpretación de la Prueba F

- Si F es grande \Rightarrow el modelo explica mucha más variabilidad que la media.
- Valor-p:
 - ▶ p -valor pequeño \Rightarrow rechazamos H_0 .
 - ▶ Conclusión: el modelo es significativo en conjunto.
- Limitación: no indica qué variables son responsables del efecto.

Ejemplo: Prueba F

- Modelo lineal con $p = 3$ predictores, $n = 50$ datos.
- Resultado: $F = 12,4$, p -valor < 0,001.
- Conclusión: el modelo es significativamente mejor que usar solo la media.

Pruebas t para Coeficientes

- Objetivo: evaluar si cada predictor contribuye significativamente.
- Hipótesis:

$$H_0 : \beta_j = 0 \quad \text{vs} \quad H_a : \beta_j \neq 0$$

- Estadístico t:

$$t = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)}$$

Interpretación de la Prueba t

- Si $|t|$ es grande \Rightarrow evidencia contra H_0 .
- Valor-p:
 - ▶ p -valor pequeño \Rightarrow el predictor j es significativo.
- Limitación: múltiples pruebas aumentan el riesgo de falsos positivos.

Ejemplo: Pruebas t

- Predictor: nivel educativo en un modelo de ingresos.
- Resultado: $\hat{\beta}_{edu} = 2,3$, $SE = 0,7$, $t = 3,29$, $p = 0,002$.
- Conclusión: el nivel educativo tiene un efecto significativo sobre ingresos.

Intervalos de Confianza para Coeficientes

- Definición: rango plausible para el valor verdadero de β_j .
- Fórmula:

$$IC_{(1-\alpha)} : \hat{\beta}_j \pm t_{\alpha/2, n-p-1} \cdot SE(\hat{\beta}_j)$$

- Nivel común: 95 %.

Interpretación de Intervalos de Confianza

- Si el intervalo incluye 0 → no hay evidencia fuerte de efecto.
- Si el intervalo excluye 0 → predictor significativo.
- Relación con prueba t: equivalentes en su conclusión al mismo nivel α .

Ejemplo

$\beta_1 \in [0,5, 1,2] \Rightarrow$ significativo. $\beta_2 \in [-0,3, 0,8] \Rightarrow$ no significativo.

Evaluación Bayesiana de Coeficientes

- En lugar de pruebas F o t, usamos la **distribución posterior** de cada coeficiente β_j .
- Posterior:

$$p(\beta_j | y) \propto p(y | \beta_j) p(\beta_j)$$

- Pregunta clave:

$$P(\beta_j \approx 0 | y)$$

- Si la mayor parte de la masa posterior está lejos de 0, concluimos que β_j es importante.

Probabilidad de Efecto Nulo vs. Diferente de Cero

- Podemos calcular:

$$P(\beta_j > 0 \mid y) \quad \text{o} \quad P(\beta_j < 0 \mid y)$$

- En vez de un *p*-valor, obtenemos probabilidades directas.
- También usamos intervalos creíbles (HPD):

$$CI_{95\%} = [a, b] \quad \text{tal que } P(\beta_j \in [a, b] \mid y) = 0,95$$

- Interpretación:

- ▶ Si 0 está fuera del intervalo $\rightarrow \beta_j$ es significativo.
- ▶ Si 0 está dentro \rightarrow evidencia débil.

AIC: Definición

- Criterio propuesto por Hirotugu Akaike (1973).
- Mide el compromiso entre:
 - ▶ **Bondad de ajuste:** qué tan bien explica los datos.
 - ▶ **Complejidad:** número de parámetros k .
- Fórmula:

$$AIC = 2k - 2 \ln(L)$$

donde L = verosimilitud máxima.

AIC: Interpretación

- Menor AIC \Rightarrow mejor modelo.
- Comparación relativa:

$$\Delta AIC_i = AIC_i - \min(AIC)$$

- Regla práctica:
 - ▶ $\Delta AIC \leq 2$: modelos comparables.
 - ▶ $4 \leq \Delta AIC \leq 7$: evidencia moderada contra el modelo.
 - ▶ $\Delta AIC > 10$: modelo muy poco probable.

AIC: Uso Práctico

- Útil para comparar modelos no anidados.
- Ampliamente usado en selección de modelos (ej. ecología, biología).
- Limitaciones:
 - ▶ No busca el “verdadero modelo”, sino el que mejor predice.
 - ▶ Puede favorecer modelos más complejos.

BIC: Definición

- También conocido como criterio de Schwarz (1978).
- Relacionado con la aproximación bayesiana al cálculo de evidencias.
- Fórmula:

$$BIC = \ln(n)k - 2\ln(L)$$

donde n = tamaño de muestra, k = número de parámetros.

BIC: Interpretación

- Penaliza más fuertemente la complejidad que AIC.
- Menor BIC \Rightarrow mejor modelo.
- Con n grande, favorece modelos más simples.
- Basado en aproximaciones asintóticas bayesianas al Bayes Factor.

BIC: Uso Práctico

- Adecuado cuando se busca identificar el modelo “verdadero” entre candidatos.
- Muy usado en contextos de inferencia estadística más que de predicción.
- Regla práctica de comparación:
 - ▶ $\Delta BIC > 10$: evidencia muy fuerte contra el modelo.

AIC vs BIC: Comparación

- Ambos penalizan modelos complejos, pero de forma distinta:

$$AIC : 2k \quad BIC : \ln(n)k$$

- Diferencias clave:

- ▶ **AIC**: Mejor para predicción (elige modelos que generalizan).
 - ▶ **BIC**: Mejor para identificación del modelo verdadero.

- Regla general:

- ▶ AIC tiende a elegir modelos más complejos.
 - ▶ BIC tiende a elegir modelos más simples.

Evaluación de la Regresión Logística: Similitudes y Diferencias

- **Similitudes con la regresión lineal:**

- ▶ Buscamos explicar/predicir una variable respuesta a partir de predictores.
- ▶ Podemos evaluar ajuste global y significancia de coeficientes.
- ▶ Usamos criterios de información (AIC, BIC) para comparar modelos.

- **Diferencias clave:**

- ▶ La respuesta Y es binaria (0/1), no continua.
- ▶ No existen R^2 ni supuestos de normalidad/homocedasticidad de residuales.
- ▶ La inferencia se basa en la **verosimilitud**, no en cuadrados mínimos.

- **Herramientas específicas:**

- ▶ **Bondad de ajuste:** Log-verosimilitud, pruebas de razón de verosimilitud, pseudo- R^2 .
- ▶ **Clasificación:** matriz de confusión, sensibilidad, especificidad, precisión, exactitud.
- ▶ **Capacidad discriminativa:** curva ROC y AUC.
- ▶ **Calibración:** prueba Hosmer–Lemeshow.

Log-Verosimilitud en Regresión Logística

- La estimación se basa en la verosimilitud:

$$L(\beta) = \prod_{i=1}^n \pi(x_i)^{y_i} [1 - \pi(x_i)]^{1-y_i}$$

donde $\pi(x_i) = \frac{e^{x_i\beta}}{1+e^{x_i\beta}}$.

- Se trabaja con la **log-verosimilitud**:

$$\ell(\beta) = \sum_{i=1}^n \left[y_i \ln(\pi(x_i)) + (1 - y_i) \ln(1 - \pi(x_i)) \right]$$

- Valores más altos (menos negativos) indican mejor ajuste.

Prueba de Razón de Verosimilitud

- Compara un modelo completo con un modelo reducido (ej. nulo).

- Estadístico:

$$G^2 = -2(\ell_{\text{reducido}} - \ell_{\text{completo}})$$

- Bajo H_0 : $G^2 \sim \chi^2_{df}$
- p -valor pequeño → el modelo completo mejora significativamente al nulo.

Matriz de Confusión

		Predicho 0	Predicho 1	
Real 0	TN	FP		
	FN	TP		

- Resume los aciertos y errores de clasificación.

Métricas Derivadas

- **Precisión:** $\frac{TP}{TP+FP}$
- **Sensibilidad (Recall):** $\frac{TP}{TP+FN}$
- **Especificidad:** $\frac{TN}{TN+FP}$
- **Exactitud:** $\frac{TP+TN}{N}$

Punto de corte

Por defecto = 0.5, pero puede ajustarse según el balance entre sensibilidad y especificidad.

Curva ROC: Concepto

- ROC = Receiver Operating Characteristic.
- Compara la capacidad de un modelo para distinguir entre clases 0 y 1.
- Se basa en dos métricas:

$$\text{Sensibilidad} = \frac{TP}{TP + FN}$$

$$1 - \text{Especificidad} = \frac{FP}{FP + TN}$$

- Ejes del gráfico:
 - ▶ x = tasa de falsos positivos (1 - especificidad).
 - ▶ y = tasa de verdaderos positivos (sensibilidad).

Curva ROC: Construcción Paso a Paso

- ① El modelo produce probabilidades \hat{p}_i para cada observación.
- ② Elegimos un **punto de corte** (ej. 0.5).
- ③ Clasificamos:
 - ▶ $\hat{p}_i \geq 0,5 \Rightarrow$ clase 1.
 - ▶ $\hat{p}_i < 0,5 \Rightarrow$ clase 0.
- ④ Calculamos:
 - ▶ Sensibilidad.
 - ▶ Especificidad.
- ⑤ Obtenemos un punto en el plano ROC.

De un Punto a la Curva Completa

- Repetimos el proceso para muchos puntos de corte (ej. 0.1, 0.2, ..., 0.9).
- Cada corte genera un par (FPR, TPR).
- Conectamos los puntos para formar la curva ROC.

Referencias visuales

- Línea diagonal = clasificador aleatorio.
- Curva por encima de la diagonal = modelo con poder discriminativo.

ROC paso a paso: 1) Datos y probabilidades

- Supón un modelo logístico que entrega probabilidades $\hat{p}_i = P(Y=1 | x_i)$.
- Tenemos 10 observaciones, con 5 positivos (1) y 5 negativos (0).
- Ordenamos por \hat{p} de mayor a menor (esto facilita recorrer umbrales).

ID	y (real)	\hat{p} (pred.)
1	1	0.95
2	1	0.85
3	0	0.80
4	1	0.70
5	0	0.60
6	1	0.55
7	0	0.40
8	0	0.30
9	1	0.20
10	0	0.10

⇒ Totales: Positivos = 5, Negativos = 5. Recorremos umbrales t desde 1.00 ↓ 0.00 y en cada t :

$$\hat{y}_i(t) = \mathbb{I}\{\hat{p}_i \geq t\}, \quad TPR(t) = \frac{TP}{TP + FN}, \quad FPR(t) = \frac{FP}{FP + TN}.$$

ROC paso a paso: 2) Primeros umbrales, conteos y tasas

- $t > 0,95$ (ningún caso predicho 1): $TP = 0, FP = 0, FN = 5, TN = 5 \Rightarrow TPR = 0/5 = 0, FPR = 0/5 = 0.$
- $t = 0,95$: predichos 1 = {ID 1 ($y = 1$)} $\Rightarrow TP = 1, FP = 0, FN = 4, TN = 5 \Rightarrow TPR = 1/5 = 0,20, FPR = 0.$
- $t = 0,85$: predichos 1 = {1(1), 2(1)} $\Rightarrow TP = 2, FP = 0 \Rightarrow TPR = 0,40, FPR = 0.$
- $t = 0,80$: predichos 1 = {1(1), 2(1), 3(0)} $\Rightarrow TP = 2, FP = 1 \Rightarrow TPR = 0,40, FPR = 1/5 = 0,20.$
- $t = 0,70$: añade 4(1) $\Rightarrow TP = 3, FP = 1 \Rightarrow TPR = 0,60, FPR = 0,20.$

t	Pred. 1	TP	FP	FN	TN	(FPR, TPR)
$> 0,95$	\emptyset	0	0	5	5	(0.00, 0.00)
0.95	{1}	1	0	4	5	(0.00, 0.20)
0.85	{1,2}	2	0	3	5	(0.00, 0.40)
0.80	{1,2,3}	2	1	3	4	(0.20, 0.40)
0.70	{1,2,3,4}	3	1	2	4	(0.20, 0.60)

\Rightarrow Cada fila es un punto ROC: eje x = FPR, eje y = TPR.

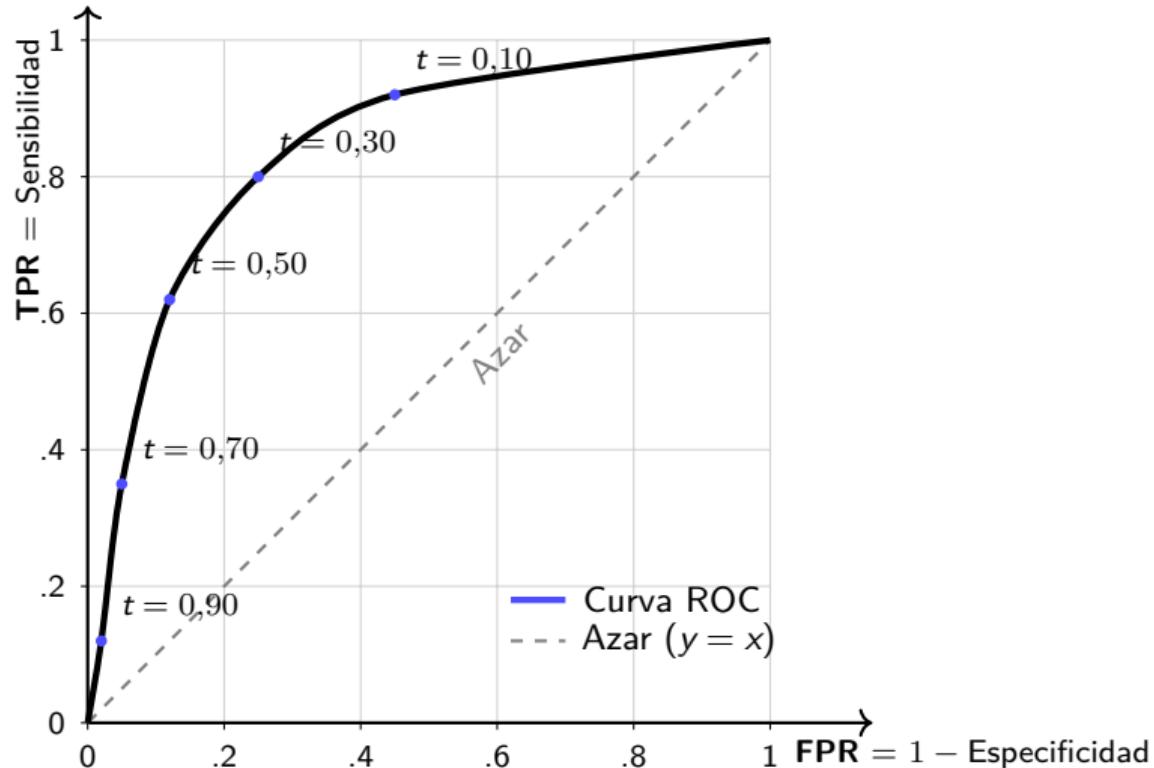
ROC paso a paso: 3) Todos los puntos y la curva

- Continuamos bajando t por cada \hat{p} único:

t	FPR	TPR
> 0,95	0.00	0.00
0.95	0.00	0.20
0.85	0.00	0.40
0.80	0.20	0.40
0.70	0.20	0.60
0.60	0.40	0.60
0.55	0.40	0.80
0.40	0.60	0.80
0.30	0.80	0.80
0.20	0.80	1.00
0.10	1.00	1.00

- Cómo trazar:** Grafica los pares (FPR, TPR) en el plano y únelos en orden de t descendente.
- Referencia:** la línea diagonal $y = x$ es el desempeño aleatorio.
- Lectura:** curvas más “al noroeste” (mayor TPR con menor FPR) indican mejor discriminación.

Curva ROC: Visualización



Nota: Más arriba/izquierda \Rightarrow mejor discriminación (mayor TPR con menor FPR).

Área Bajo la Curva (AUC)

- AUC = probabilidad de que el modelo asigne mayor probabilidad a un positivo que a un negativo.
- Valores típicos:
 - ▶ 0.5 → modelo sin discriminación (equivalente a azar).
 - ▶ 0.7–0.8 → aceptable.
 - ▶ 0.8–0.9 → excelente.
 - ▶ >0.9 → sobresaliente.
- Ventaja: independiente del punto de corte elegido.

Bibliografía

-  Draper, N. R., & Smith, H. (1998). *Applied Regression Analysis* (3rd ed.). Wiley.
-  Weisberg, S. (2005). *Applied Linear Regression* (3rd ed.). Wiley.
-  Montgomery, D. C., Peck, E. A., & Vining, G. G. (2021). *Introduction to Linear Regression Analysis* (6th ed.). Wiley.
-  Kutner, M. H., Nachtsheim, C. J., & Neter, J. (2004). *Applied Linear Regression Models* (4th ed.). McGraw-Hill/Irwin.
-  Akaike, H. (1974). A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, 19(6), 716–723.
-  Schwarz, G. (1978). Estimating the dimension of a model. *The Annals of Statistics*, 6(2), 461–464.
-  Burnham, K. P., & Anderson, D. R. (2002). *Model Selection and Multimodel Inference: A Practical Information-Theoretic Approach* (2nd ed.). Springer.
-  Belsley, D. A., Kuh, E., & Welsch, R. E. (2005). *Regression Diagnostics: Identifying Influential Data and Sources of Collinearity*. Wiley.
-  Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied Logistic Regression* (3rd ed.). Wiley.