

Introducción a la Ciencia de Datos

Maestría en Probabilidad y Estadística

Dr. Marco Antonio Aquino López

Centro de Investigación en Matemáticas

Agosto-Diciembre 2025

Matrices y datos

- Los arreglos matriciales son el objeto natural para guardar información cuantitativa en Ciencias de Datos.

individuos	atributos			
	1	2	\dots	p
1				
2				
.				
.				
n				

individuos	atributos
clientes	características del cliente
clientes	preferencias y niveles de compra
imágenes	niveles de color en pixeles
individuos	ratings
individuos	niveles de expresión de genes
textos	frecuencias de palabras
moléculas	descriptores
regiones	abundancia de especies

- En las aplicaciones se encuentran todos los casos:

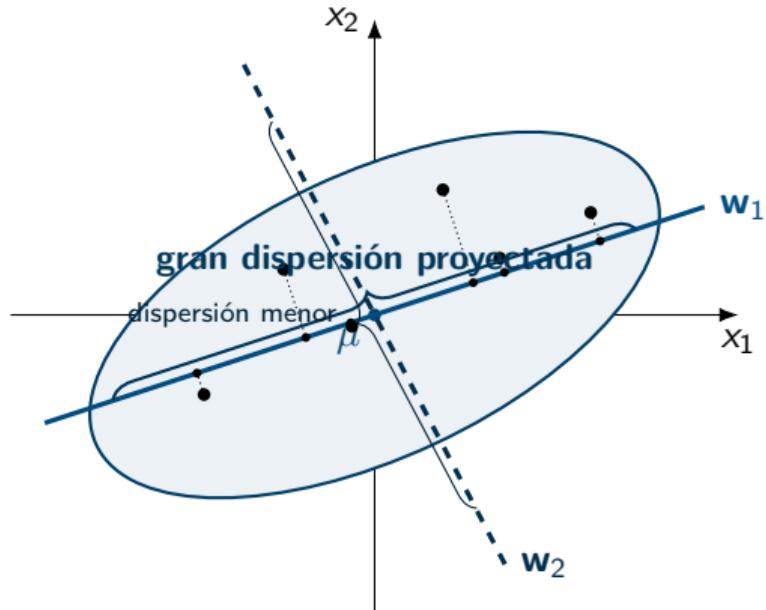
$$n \gg p, \quad n > p, \quad n \approx p, \quad n < p, \quad n \ll p$$

Motivación: ¿Por qué reducir la dimensionalidad?

- **Curse of dimensionality:** en alta dimensión, distancias se vuelven menos informativas; la intuición geométrica falla.
- **Redundancia:** variables correlacionadas aportan información repetida.
- **Ruido:** direcciones de baja varianza pueden distorsionar clustering.
- **Visualización:** requerimos proyecciones 2D/3D para inspección de clusters.

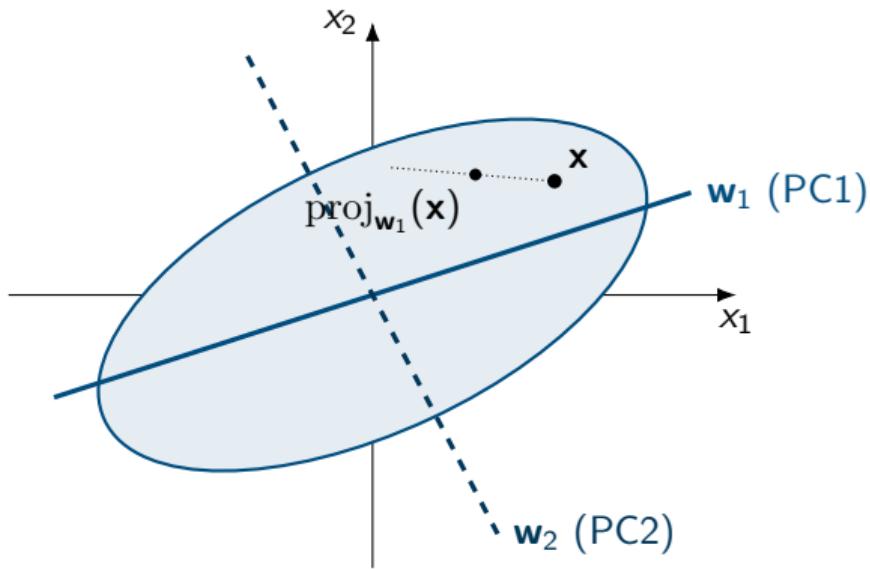
Idea central: encontrar un subespacio k -dimensional ($k \ll p$) que *preserve* la estructura esencial (variabilidad/vecindades) con *mínima pérdida* de información.

Intuición: direcciones de máxima varianza



- w_1 maximiza esa dispersión (intuición de PCA).

Geometría: direcciones de máxima varianza



\mathbf{w}_1 : dirección que *maximiza* la varianza proyectada; \mathbf{w}_2 : siguiente dirección ortogonal con máxima varianza residual.

Hacia el formalismo

Idea clave: elegir \mathbf{w}_1 para *maximizar* la varianza de las proyecciones de datos centrados X_c sobre \mathbf{w}_1 .

- Datos centrados: $X_c = X - \mathbf{1}\mu^\top$.
- Proyección: $t_i = \mathbf{w}^\top \mathbf{x}_{c,i}$.
- Varianza (muestral):

$$\hat{\sigma}^2(\mathbf{w}) = \frac{1}{n-1} \sum_{i=1}^n (t_i - \bar{t})^2.$$

- Con centrado, $\bar{t} = 0$, y

$$\hat{\sigma}^2(\mathbf{w}) = \mathbf{w}^\top \left(\frac{1}{n-1} X_c^\top X_c \right) \mathbf{w}.$$

Problema (preliminar)

$$\max_{\|\mathbf{w}\|=1} \mathbf{w}^\top S \mathbf{w}, \quad S = \frac{1}{n-1} X_c^\top X_c.$$

Siguiente: mostrar que la solución es el *eigenvector principal*.

Fundamento matemático de PCA

Planteamiento

Sea $X_c \in \mathbb{R}^{n \times p}$ el conjunto de datos centrados y $S = \frac{1}{n} X_c^\top X_c$ su matriz de covarianzas muestral.

Theorem (Dirección de máxima varianza)

Sea $\mathbf{w} \in \mathbb{R}^p$ con $\|\mathbf{w}\| = 1$. La varianza de las proyecciones $t_i = \mathbf{w}^\top \mathbf{x}_{c,i}$ es $\sigma^2(\mathbf{w}) = \mathbf{w}^\top S \mathbf{w}$. La dirección que maximiza $\sigma^2(\mathbf{w})$ es el **autovector principal** de S asociado a su mayor autovalor λ_1 .

Esquema.

Resolvemos

$$\max_{\mathbf{w}} \mathbf{w}^\top S \mathbf{w} \quad \text{sujeto a } \|\mathbf{w}\|^2 = 1.$$

Formamos el Lagrangiano

$$\mathcal{L}(\mathbf{w}, \lambda) = \mathbf{w}^\top S \mathbf{w} - \lambda(\mathbf{w}^\top \mathbf{w} - 1),$$

y derivando respecto a \mathbf{w} :

$$\nabla_{\mathbf{w}} \mathcal{L} = 2S\mathbf{w} - 2\lambda\mathbf{w} = 0 \implies S\mathbf{w} = \lambda\mathbf{w}.$$

λ es la varianza proyectada y la dirección óptima \mathbf{w}_1 corresponde al mayor λ .



Subespacio de dimensión k y ortogonalidad

Proposición (Bases ortogonales de componentes principales)

Sea $W_k = [\mathbf{w}_1, \dots, \mathbf{w}_k] \in \mathbb{R}^{p \times k}$ con $\mathbf{w}_i^\top \mathbf{w}_j = \delta_{ij}$. El problema generalizado de PCA es

$$\max_{W_k^\top W_k = I_k} \text{Tr}(W_k^\top S W_k).$$

Resultado

Por el teorema espectral, la solución está dada por los k eigenvectores principales de S :

$$S = V \Lambda V^\top, \quad W_k = [\mathbf{v}_1, \dots, \mathbf{v}_k],$$

donde $\lambda_1 \geq \dots \geq \lambda_p$ son los eigenvalores.

Varianza explicada y su interpretación

Autovalores y varianza proyectada

Para cada componente principal \mathbf{w}_i :

$$S\mathbf{w}_i = \lambda_i \mathbf{w}_i, \quad \|\mathbf{w}_i\| = 1.$$

La varianza de las proyecciones sobre \mathbf{w}_i es

$$\text{Var}(\mathbf{w}_i^\top X_c) = \mathbf{w}_i^\top S \mathbf{w}_i = \lambda_i.$$

Varianza total

La varianza total de los datos centrados es la traza de S :

$$\text{tr}(S) = \sum_{j=1}^p S_{jj} = \sum_{i=1}^p \lambda_i.$$

Fracción de varianza explicada (EVR)

$$\text{EVR}(k) = \frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^p \lambda_i}, \quad \text{con } \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p.$$

Interpretación: mide qué proporción de la dispersión total se conserva.

Motivación: del máximo de varianza al mínimo de error

Hasta ahora, PCA se formuló como el problema de encontrar las direcciones que *maximizan la varianza proyectada*.

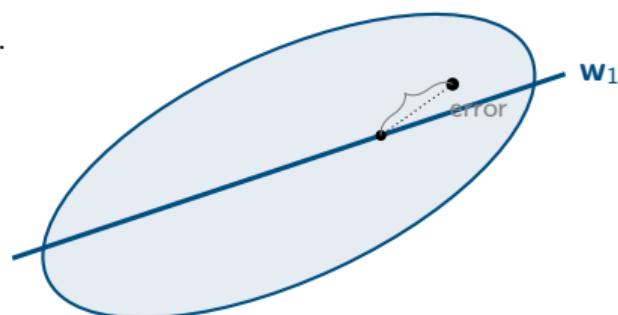
Otra visión equivalente —y útil desde un punto de vista geométrico y de compresión— es:

Idea principal

Buscar el subespacio lineal de dimensión k que **minimiza el error cuadrático medio de reconstrucción**.

- Los datos se “comprimen” al proyectarse en un plano o subespacio.
- Luego se “reconstruyen” desde ese subespacio.
- La mejor proyección es la que minimiza la pérdida de información:

$$\min_{\hat{X}} \|X_c - \hat{X}\|_F^2.$$



Formulación matemática del problema

Sea $X_c \in \mathbb{R}^{n \times p}$ el conjunto de datos centrado. Buscamos matrices $W \in \mathbb{R}^{p \times k}$ y $Z \in \mathbb{R}^{n \times k}$ que minimicen:

$$\min_{Z, W} \|X_c - ZW^\top\|_F^2 \text{ sujeto a } W^\top W = I_k.$$

- W : define las **direcciones ortonormales** del subespacio (loadings).
- Z : contiene las **coordenadas proyectadas** (scores).

Interpretación

$\hat{X} = ZW^\top$ es una reconstrucción de rango k del conjunto de datos. El objetivo es minimizar el error cuadrático medio de reconstrucción.

Proyección óptima sobre un subespacio

Dado un subespacio generado por las columnas de W , la mejor reconstrucción de los datos se obtiene al proyectarlos ortogonalmente sobre dicho subespacio.

Problema

$$\min_{Z, W} \|X_c - ZW^\top\|_F^2 \text{ sujeto a } W^\top W = I_k.$$

- Para un W fijo, la solución óptima para Z es:

$$Z = X_c W.$$

- Intuitivamente: cada fila de Z son las coordenadas de un punto proyectado sobre el subespacio generado por W .

Conclusión: PCA proyecta los datos de manera ortogonal sobre el subespacio de menor dimensión.

Reducción a un problema en W

Sustituyendo $Z = X_c W$ en la función de error, obtenemos:

$$J(W) = \|X_c - X_c W W^\top\|_F^2.$$

Interpretación geométrica

- WW^\top es el proyector ortogonal sobre el subespacio generado por W .
- $I - WW^\top$ mide la distancia de cada punto a su proyección.

Resultado clave

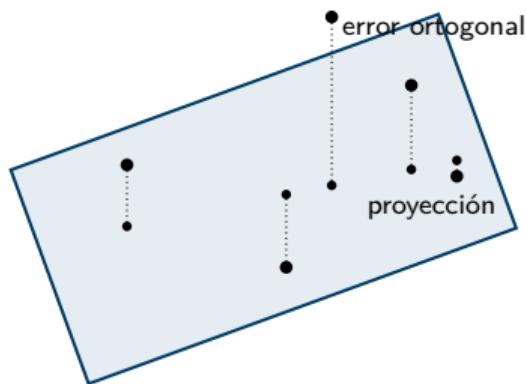
Minimizar el error equivale a maximizar la varianza retenida:

$$\min_W J(W) \iff \max_{W^\top W = I_k} \text{tr}(W^\top X_c^\top X_c W).$$

Interpretación geométrica y error de reconstrucción

- PCA busca el subespacio de dimensión k que *minimiza la distancia ortogonal promedio* entre los puntos y el plano de proyección.
- La reconstrucción es $\hat{X} = X_c W W^\top$.
- El error cuadrático mínimo se relaciona con los eigenvalores omitidos:

$$\|X_c - \hat{X}\|_F^2 = (n - 1) \sum_{i=k+1}^p \lambda_i.$$



Conclusión: PCA proporciona la mejor aproximación lineal (en MSE) de los datos en un subespacio de rango k .

Code

Motivación: de la covarianza a la SVD

La formulación clásica de PCA usa la matriz de covarianza

$$S = \frac{1}{n-1} X_c^\top X_c.$$

Sin embargo, calcular sus eigenvectores puede ser costoso cuando p es grande o $n < p$.

Idea

Usar la **descomposición en valores singulares (SVD)** del conjunto de datos centrado:

$$X_c = U \Sigma V^\top.$$

- U : direcciones ortogonales de las **observaciones**.
- V : direcciones ortogonales de las **variables**.
- Σ : valores singulares (miden la escala de variación).

Ventaja: Evita calcular S directamente y es numéricamente estable.

Conexión entre SVD y PCA

Multiplicando $X_c = U\Sigma V^\top$ por X_c^\top :

$$S = \frac{1}{n-1} X_c^\top X_c = V \left(\frac{\Sigma^\top \Sigma}{n-1} \right) V^\top.$$

Consecuencias

- Los **autovectores** de S son las columnas de V .
- Los **autovalores** son $\lambda_i = \sigma_i^2 / (n - 1)$.
- Los **componentes principales (scores)** son:

$$Z = X_c V_k = U_k \Sigma_k.$$

Interpretación: la SVD reexpresa los datos como una rotación ortogonal + escalamiento según su varianza.

Interpretación geométrica de la SVD

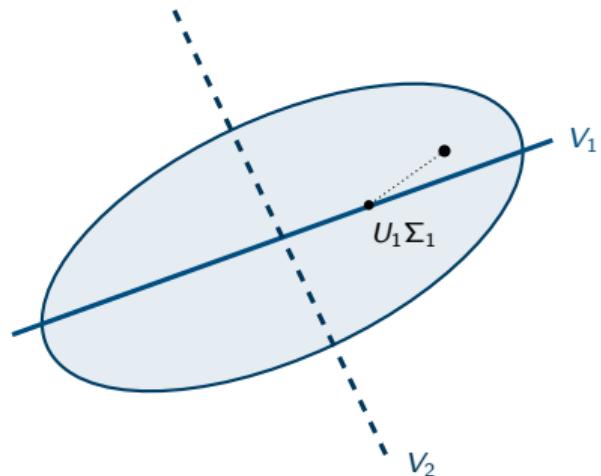
- V_k : ejes principales (direcciones de máxima varianza).
- $U_k \Sigma_k$: coordenadas proyectadas de cada punto en esos ejes.
- La reconstrucción de rango k es:

$$\hat{X}_k = U_k \Sigma_k V_k^\top.$$

- El error de reconstrucción:

$$\|X_c - \hat{X}_k\|_F^2 = (n-1) \sum_{i=k+1}^p \lambda_i.$$

Conclusión: La SVD muestra que PCA es una *rotación ortogonal* que ordena las direcciones según la varianza de los datos.



Pausa

Pausa

Reducción de dimensión: un recordatorio

En aprendizaje no supervisado, la reducción de dimensión busca representar los datos $X \in \mathbb{R}^{n \times p}$ en un espacio de menor dimensión $r \ll p$.

- **PCA/SVD:** encuentra combinaciones lineales ortogonales que maximizan la varianza.
- **Problema:** las combinaciones pueden ser negativas, lo cual dificulta la interpretación.

Ejemplo: matriz de imágenes o conteos

Si cada pixel o palabra tiene un valor no negativo, ¿cómo interpretamos una combinación lineal con pesos negativos?

Necesitamos una descomposición “aditiva”, no sustractiva.

Idea central de NMF

La **Factorización No Negativa de Matrices (NMF)** busca representar los datos como

$$V \approx WH, \quad \text{con } W, H \geq 0.$$

- Cada columna de V (una observación) se aproxima como combinación *aditiva* de las columnas de W .
- Las columnas de W representan **partes básicas o temas latentes**.
- Las filas de H indican **cuánto contribuye cada parte** en cada observación.

Interpretación: NMF descubre estructuras interpretables, con componentes positivos que “se suman” para formar el todo.

Factorización no negativa de matrices

NMF aproxima los datos, en los renglones de $W_{n \times p}$ (W con entradas no negativas), como combinaciones lineales de una base $V_{p \times k}$ y pesos $U_{n \times k}$:

$$W \approx U V^\top$$

$$W = \begin{bmatrix} w_1^\top \\ \vdots \\ w_n^\top \end{bmatrix} \approx \begin{bmatrix} u_1^\top \\ \vdots \\ u_n^\top \end{bmatrix} V^\top$$

y para cada fila i : $w_i \approx V u_i = u_{i1} v_1 + \dots + u_{ik} v_k$.

$$W \approx U V^\top, \quad U, V \geq 0$$

donde el rango k de la factorización es definido por el usuario.

Comparación conceptual con PCA

PCA: combinación positiva y negativa

$$\mathbf{x} \approx 0.6v_1 - 0.4v_2$$

NMF: combinación sólo aditiva

$$\mathbf{x} \approx 0.6w_1 + 0.4w_2$$

resta de componentes

suma de "partes"

NMF: interpretabilidad por aditividad

Ejemplo

En análisis de texto, cada documento se representa como mezcla de temas; en imágenes, cada rostro como combinación de partes (ojos, nariz, boca).

Aplicaciones típicas

- **Minería de textos:** detección de temas latentes.
- **Reconocimiento facial:** representación por “partes” en lugar de vectores globales.
- **Recomendadores:** descubrimiento de grupos de usuarios o productos.

$$V \approx WH$$

⇒ datos = combinación positiva de factores interpretables

Definición del problema

Sea $V \in \mathbb{R}^{m \times n}$ una matriz de datos con $V_{ij} \geq 0$. Buscamos dos matrices:

$$W \in \mathbb{R}^{m \times r}, \quad H \in \mathbb{R}^{r \times n},$$

tales que:

$$W_{ik} \geq 0, \quad H_{kj} \geq 0, \quad \text{y} \quad V \approx WH.$$

Dimensiones

$$\underbrace{V}_{m \times n} \approx \underbrace{W}_{m \times r} \underbrace{H}_{r \times n}$$

- r : número de factores latentes o “componentes”.
- Columnas de W : patrones o partes básicas.
- Filas de H : pesos no negativos para cada observación.

Función objetivo general

El problema de NMF se formula como:

$$\min_{W, H \geq 0} f(V, W, H) \quad \text{donde} \quad f(V, W, H) = D(V \| WH)$$

y $D(\cdot \| \cdot)$ es una **divergencia** o medida de error entre matrices.

Dos funciones de costo más comunes

① Norma de Frobenius:

$$D_F(V \| WH) = \frac{1}{2} \| V - WH \|_F^2 = \frac{1}{2} \sum_{ij} (V_{ij} - (WH)_{ij})^2.$$

② Divergencia de Kullback–Leibler:

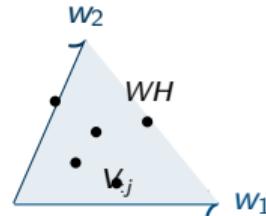
$$D_{KL}(V \| WH) = \sum_{ij} \left(V_{ij} \log \frac{V_{ij}}{(WH)_{ij}} - V_{ij} + (WH)_{ij} \right).$$

Ambas funciones son convexas en W o en H individualmente, pero no en el par (W, H) .

Interpretación geométrica

- Cada columna de V se representa como combinación no negativa de las columnas de W .
- El conjunto de todas las combinaciones posibles de W forma un **cono convexo**.
- NMF busca el cono convexo de dimensión r que mejor aproxima a los datos.

La factorización busca una representación aditiva dentro de un cono positivo.



Naturaleza no convexa del problema

El problema

$$\min_{W,H \geq 0} D(V||WH)$$

no es convexo en W y H simultáneamente.

Consecuencias prácticas

- No existe garantía de encontrar el mínimo global.
- Se usan métodos iterativos (alternar entre W y H).
- La calidad del resultado depende de la inicialización.

Idea clave: aunque es no convexo, suele producir soluciones significativas e interpretables.

Panorama del problema

Recordatorio: dado $V \in \mathbb{R}_+^{m \times n}$, buscamos $W \in \mathbb{R}_+^{m \times r}$, $H \in \mathbb{R}_+^{r \times n}$ con

$$\min_{W,H \geq 0} D(V \| WH),$$

donde típicamente

$$D_F(V \| WH) = \frac{1}{2} \| V - WH \|_F^2, \quad D_{\text{KL}}(V \| WH) = \sum_{ij} \left(V_{ij} \log \frac{V_{ij}}{(WH)_{ij}} - V_{ij} + (WH)_{ij} \right).$$

- Problema no convexo en (W, H) conjunto; convexo en cada bloque por separado.
- Estrategia: **alternar** actualizando H con W fijo, y viceversa.

Actualizaciones multiplicativas (MU) para Frobenius

Para $D_F(V||WH) = \frac{1}{2} \|V - WH\|_F^2$, las reglas MU clásicas (Lee & Seung) son:

$$H \leftarrow H \odot \frac{W^\top V}{W^\top WH + \varepsilon}$$

$$W \leftarrow W \odot \frac{VH^\top}{WHH^\top + \varepsilon}$$

donde \odot y la fracción son operaciones *elemento a elemento*; $\varepsilon > 0$ evita divisiones por cero.

- Se derivan imponiendo KKT y usando *majorization-minimization* para garantizar $\Delta D_F \leq 0$.
- Mantienen la no negatividad (multiplican por factores ≥ 0).
- Sencillas de implementar; convergencia sublineal; sensibles a escalado.

Esquema alternado

- ① Con W fijo, actualiza H con la regla MU.
- ② Con H fijo, actualiza W con la regla MU.
- ③ Repite hasta parada (tolerancia o máximo de iteraciones).

Actualizaciones multiplicativas (MU) para KL

Para la divergencia de Kullback–Leibler:

$$D_{\text{KL}}(V \parallel WH) = \sum_{ij} \left(V_{ij} \log \frac{V_{ij}}{(WH)_{ij}} - V_{ij} + (WH)_{ij} \right),$$

las reglas MU son:

$$H \leftarrow H \odot \frac{W^T \left(\frac{V}{WH} \right)}{W^T \mathbf{1}}$$

$$W \leftarrow W \odot \frac{\left(\frac{V}{WH} \right) H^T}{\mathbf{1} H^T}$$

donde $\frac{V}{WH}$ es elemento a elemento y $\mathbf{1}$ es una matriz/tensor de unos con dimensiones compatibles.

- Muy usada en *text mining* y conteos tipo Poisson.
- También garantiza no incremento de D_{KL} bajo condiciones estándar.

Referencias

-  Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
-  Mohri, M., Rostamizadeh, A., & Talwalkar, A. (2018). *Foundations of Machine Learning* (2nd ed.). MIT Press.
-  Jolliffe, I. T. (2002). *Principal Component Analysis* (2nd ed.). Springer.
-  Lee, D. D., & Seung, H. S. (1999). Learning the parts of objects by non-negative matrix factorization. *Nature*, **401**, 788–791.