



Tarea 3

Ciencia de Datos.

Alfredo Bistrain
Jesús Salazar

October 14, 2025

Ejercicio



1 Regresión lineal ordinaria (OLS)

1. Derivación del estimador OLS: Partiendo del modelo clásico

$$y = X\beta + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2 I)$$

demuestre que el estimador de Mínimos Cuadrados Ordinarios es

$$\hat{\beta} = (X^\top X)^{-1} X^\top y$$

siempre que $X^\top X$ sea invertible.

2. Propiedades del estimador: Calcule explícitamente:

$$E[\hat{\beta}], \quad \text{Var}(\hat{\beta}).$$

Concluya que $\hat{\beta}$ es insesgado y eficiente dentro de la clase de estimadores lineales (teorema de Gauss-Markov).

Solución:

Considere el modelo de regresión lineal,

$$\mathbf{Y} = X\beta + \epsilon$$

donde $\epsilon \sim N(0, \sigma^2 I_n)$. Se busca al valor de $\hat{\beta}$ que minimice la suma de los errores al cuadrado, es decir,

$$\begin{aligned} SS_{\text{Res}}(\beta) &= \sum_{i=1}^n (y_i - [X\beta]_i)^2 \\ &= (y - X\beta)^\top (y - X\beta) \\ &= \mathbf{y}^\top \mathbf{y} - \mathbf{y}^\top X\beta - \beta^\top X^\top \mathbf{y} + \beta^\top X^\top X\beta \\ &= \mathbf{y}^\top \mathbf{y} - 2\mathbf{y}^\top X\beta + \beta^\top X^\top X\beta. \end{aligned}$$

Derivando la expresión anterior con respecto a β y notando que $X^\top X$ es una matriz

simétrica, se tiene,

$$\begin{aligned}\frac{\partial SS_{\text{Res}}(\boldsymbol{\beta})}{\partial \boldsymbol{\beta}} &= (-2\mathbf{y}^\top X)^\top + 2X^\top X\boldsymbol{\beta} \\ &= -2X^\top \mathbf{y} + 2X^\top X\boldsymbol{\beta}.\end{aligned}$$

Igualando a cero la expresión anterior, se puede observar que el estimador que se busca $\bar{\boldsymbol{\beta}}$ debe satisfacer

$$X^\top X\bar{\boldsymbol{\beta}} = X^\top \mathbf{y}.$$

Este sistema de ecuaciones son la ecuaciones normales para el modelo de regresión lineal. Para poder despejar $\bar{\boldsymbol{\beta}}$ es necesario que $X^\top X$ sea invertible. Esto es que tenga rango completo. En este caso,

$$\hat{\boldsymbol{\beta}} = (X^\top X)^{-1} X^\top \mathbf{y}.$$

Sabemos que $\hat{\boldsymbol{\beta}}$ minimiza $SS_{\text{Res}}(\boldsymbol{\beta})$ si y solo si la matriz Hessiana de SS_{Res} es positiva definida.

$$\begin{aligned}H &= \frac{\partial^2 SS_{\text{Res}}}{\partial \boldsymbol{\beta}^2} \\ &= (2X^\top X)^\top \\ &= 2X^\top X.\end{aligned}$$

que es positiva definida si $\text{rango}(X) = p$.

(2)

Para solucionar este inciso, basta observar que Como $\boldsymbol{\varepsilon} \sim N(\mathbf{0}, \sigma^2 I_n)$, entonces $\mathbf{Y} \sim N(X\boldsymbol{\beta}, \sigma^2 I_n)$, esto por propiedades de la distribución normal multivariada, por otro lado, observe que,

$$\mathbb{E}(\hat{\boldsymbol{\beta}}) = \mathbb{E}\left((X^\top X)^{-1} X^\top \mathbf{Y}\right) = (X^\top X)^{-1} X^\top \mathbb{E}(\mathbf{Y}) = (X^\top X)^{-1} X^\top X\boldsymbol{\beta} = \boldsymbol{\beta}.$$

Del mismo modo, la varianza de $\hat{\boldsymbol{\beta}}$ se puede obtener como,

$$\begin{aligned}\text{Var}(\hat{\boldsymbol{\beta}}) &= \text{Var}\left[(X^\top X)^{-1} X^\top \mathbf{y}\right] \\ &= (X^\top X)^{-1} X^\top \text{Var}(\mathbf{y}) \left[(X^\top X)^{-1} X^\top\right]^\top \\ &= (X^\top X)^{-1} X^\top X (X^\top X)^{-1} \sigma^2 = (X^\top X)^{-1} \sigma^2.\end{aligned}$$

De este modo,

$$\hat{\boldsymbol{\beta}} \sim N\left(\boldsymbol{\beta}, (X^\top X)^{-1} \sigma^2\right),$$

y por el teorema de Gauss-Markov, se tiene que $\hat{\boldsymbol{\beta}}$ es un estimador insesgado y eficiente.

Ejercicio

**2 Regresión lineal bayesiana (prior conjugado)**

1. Prior conjugado: Suponga un prior conjugado:

$$\beta \mid \sigma^2 \sim \mathcal{N}(\beta_0, \sigma^2 V_0), \quad \sigma^2 \sim \text{Inv-Gamma}(a_0, b_0).$$

2. Distribución posterior: Derive los parámetros posteriores (β_n, V_n, a_n, b_n) y escriba la forma explícita de la posterior conjunta

$$p(\beta, \sigma^2 \mid y)$$

3. Distribuciones marginales: Identifique las distribuciones marginales de β y de σ^2 .

Solución:

(1)

Considere el modelo de regresión lineal,

$$\mathbf{Y} = X\beta + \epsilon$$

donde $\epsilon \sim N(\mathbf{0}, \sigma^2 I_n)$. Además, suponga que los parámetros son variables aleatorias con distribuciones a priori,

$$\begin{aligned} \beta \mid \sigma^2 &\sim \mathcal{N}(\beta_0, \sigma^2 V_0) \\ \sigma^2 &\sim \text{Inv-Gamma}(a_0, b_0), \end{aligned}$$

donde V_0, β_0, a_0, b_0 son hiperparámetros de las distribuciones. De este modo, la función de verosimilitud está dada por,

$$p(y \mid \beta, \sigma^2) = (2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma^2} (y - X\beta)^\top (y - X\beta) \right\}.$$

Observe que la distribución a priori conjunta de los parámetros se puede obtener como,

$$\begin{aligned} p(\beta, \sigma^2) &= p(\beta \mid \sigma^2) p(\sigma^2) \\ &= (2\pi\sigma^2)^{-k/2} |V_0|^{-1/2} \exp \left\{ -\frac{1}{2\sigma^2} (\beta - \beta_0)^\top V_0^{-1} (\beta - \beta_0) \right\} \\ &\quad \times \frac{b_0^{a_0}}{\Gamma(a_0)} (\sigma^2)^{-a_0-1} \exp \left(-\frac{b_0}{\sigma^2} \right). \end{aligned}$$

Por otro lado, se sabe que la distribución posterior es proporcional a la expresión,

$$\begin{aligned}
p(\beta, \sigma^2 | y) &\propto p(y | \beta, \sigma^2) p(\beta | \sigma^2) p(\sigma^2) \\
&\propto (\sigma^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma^2} (y - X\beta)^\top (y - X\beta) \right\} \\
&\quad \times (\sigma^2)^{-k/2} \exp \left\{ -\frac{1}{2\sigma^2} (\beta - \beta_0)^\top V_0^{-1} (\beta - \beta_0) \right\} \\
&\quad \times (\sigma^2)^{-a_0-1} \exp \left(-\frac{b_0}{\sigma^2} \right).
\end{aligned}$$

Note que si se juntan las dos primeras exponenciales y se factoriza el termino $-\frac{1}{2\sigma^2}$, los términos dentro de la exponencial se pueden reescribir como,

$$\begin{aligned}
&(y - X\beta)^\top (y - X\beta) + (\beta - \beta_0)^\top V_0^{-1} (\beta - \beta_0) \\
&= y^\top y - 2\beta^\top X^\top y + \beta^\top X^\top X\beta + \beta^\top V_0^{-1} \beta - 2\beta^\top V_0^{-1} \beta_0 + \beta_0^\top V_0^{-1} \beta_0 \\
&= \beta^\top (X^\top X + V_0^{-1}) \beta - 2\beta^\top (X^\top y + V_0^{-1} \beta_0) + y^\top y + \beta_0^\top V_0^{-1} \beta_0.
\end{aligned}$$

Para simplificar la notación, defina,

$$\begin{aligned}
A &= X^\top X + V_0^{-1} \\
b &= X^\top y + V_0^{-1} \beta_0 \\
c &= y^\top y + \beta_0^\top V_0^{-1} \beta_0
\end{aligned}$$

Observe que la última expresión se puede reescribir como,

$$\begin{aligned}
&\beta^\top A\beta - 2\beta^\top b + c \\
&= \beta^\top A\beta - 2\beta^\top b + b^\top A^{-1}b - b^\top A^{-1}b + c \\
&= (\beta - A^{-1}b)^\top A(\beta - A^{-1}b) - b^\top A^{-1}b + c \\
&= (\beta - A^{-1}b)^\top A(\beta - A^{-1}b) + (c - b^\top A^{-1}b).
\end{aligned}$$

Regresando esta expresión a ecuación original se tiene,

$$\begin{aligned}
p(\beta, \sigma^2 | y) &\propto (\sigma^2)^{-(n+k)/2-a_0-1} \exp \left\{ -\frac{1}{2\sigma^2} [(\beta - A^{-1}b)^\top A(\beta - A^{-1}b) + (c - b^\top A^{-1}b)] - \frac{b_0}{\sigma^2} \right\} \\
&= (\sigma^2)^{-k/2} \exp \left\{ -\frac{1}{2\sigma^2} (\beta - A^{-1}b)^\top A(\beta - A^{-1}b) \right\} \\
&\quad \times (\sigma^2)^{-n/2-a_0-1} \exp \left\{ -\frac{1}{\sigma^2} \left[b_0 + \frac{1}{2}(c - b^\top A^{-1}b) \right] \right\}.
\end{aligned}$$

Así, multiplicando con las constantes adecuadas para completar las distribuciones correspondientes se tiene,

$$\begin{aligned}
p(\beta, \sigma^2 | y) &\propto \frac{1}{(2\pi\sigma^2)^{k/2} |A^{-1}|^{1/2}} \exp \left\{ -\frac{1}{2\sigma^2} (\beta - A^{-1}b)^\top A(\beta - A^{-1}b) \right\} \\
&\quad \times \frac{[b_0 + \frac{1}{2}(c - b^\top A^{-1}b)]^{a_0+n/2}}{\Gamma(a_0 + n/2)} (\sigma^2)^{-(a_0+n/2)-1} \exp \left\{ -\frac{1}{\sigma^2} \left[b_0 + \frac{1}{2}(c - b^\top A^{-1}b) \right] \right\}.
\end{aligned}$$

De esta manera, si se define a

$$\begin{aligned} V_n &= A^{-1} = (X^\top X + V_0^{-1})^{-1} \\ \beta_n &= A^{-1}b = V_n(X^\top y + V_0^{-1}\beta_0) \\ a_n &= a_0 + \frac{n}{2} \\ b_n &= b_0 + \frac{1}{2} [c - \beta_n^\top V_n^{-1} \beta_n] \\ &= b_0 + \frac{1}{2} [y^\top y + \beta_0^\top V_0^{-1} \beta_0 - \beta_n^\top V_n^{-1} \beta_n], \end{aligned}$$

se tiene que la distribución a posterior es una distribución normal-gamma inversa con parámetros, $(\beta_n, \sigma^2 V_n, a_n, b_n)$

$$\begin{aligned} p(\beta, \sigma^2 | y) &= \frac{1}{(2\pi\sigma^2)^{k/2} |V_n|^{1/2}} \exp \left\{ -\frac{1}{2\sigma^2} (\beta - \beta_n)^\top V_n^{-1} (\beta - \beta_n) \right\} \\ &\times \frac{b_n^{a_n}}{\Gamma(a_n)} (\sigma^2)^{-a_n-1} \exp \left(-\frac{b_n}{\sigma^2} \right). \end{aligned}$$

Por último, observe que la distribución a posterior marginal de parámetro σ^2 se puede encontrar a partir de la definición,

$$\begin{aligned} p(\sigma^2 | y) &= \int p(\beta, \sigma^2 | y) d\beta \\ &= \int \frac{1}{(2\pi\sigma^2)^{k/2} |V_n|^{1/2}} \exp \left\{ -\frac{1}{2\sigma^2} (\beta - \beta_n)^\top V_n^{-1} (\beta - \beta_n) \right\} \\ &\times \frac{b_n^{a_n}}{\Gamma(a_n)} (\sigma^2)^{-a_n-1} \exp \left(-\frac{b_n}{\sigma^2} \right) d\beta \\ &= \frac{b_n^{a_n}}{\Gamma(a_n)} (\sigma^2)^{-a_n-1} \exp \left(-\frac{b_n}{\sigma^2} \right) \\ &\times \int \frac{1}{(2\pi\sigma^2)^{k/2} |V_n|^{1/2}} \exp \left\{ -\frac{1}{2\sigma^2} (\beta - \beta_n)^\top V_n^{-1} (\beta - \beta_n) \right\} d\beta \\ &= \frac{b_n^{a_n}}{\Gamma(a_n)} (\sigma^2)^{-a_n-1} \exp \left(-\frac{b_n}{\sigma^2} \right) \times 1 \\ &= \frac{b_n^{a_n}}{\Gamma(a_n)} (\sigma^2)^{-a_n-1} \exp \left(-\frac{b_n}{\sigma^2} \right) \end{aligned}$$

La expresión anterior corresponde a la función de densidad de una distribución gamma-inversa con parámetros (a_n, b_n) . Por lo tanto

$$\sigma^2 | y \sim \text{Inv-Gamma}(a_n, b_n).$$

Por otro lado, la distribución posterior marginal de β se puede encontrar a partir de la

definición, esto es,

$$\begin{aligned}
 p(\beta \mid y) &= \int_0^\infty p(\beta, \sigma^2 \mid y) d\sigma^2 \\
 &= \int_0^\infty \frac{1}{(2\pi\sigma^2)^{k/2} |V_n|^{1/2}} \exp \left\{ -\frac{1}{2\sigma^2} (\beta - \beta_n)^\top V_n^{-1} (\beta - \beta_n) \right\} \\
 &\quad \times \frac{b_n^{a_n}}{\Gamma(a_n)} (\sigma^2)^{-a_n-1} \exp \left(-\frac{b_n}{\sigma^2} \right) d\sigma^2 \\
 &= \frac{b_n^{a_n}}{(2\pi)^{k/2} |V_n|^{1/2} \Gamma(a_n)} \int_0^\infty (\sigma^2)^{-(a_n+k/2)-1} \\
 &\quad \times \exp \left\{ -\frac{1}{\sigma^2} \left[b_n + \frac{1}{2} (\beta - \beta_n)^\top V_n^{-1} (\beta - \beta_n) \right] \right\} d\sigma^2 \\
 &= \frac{b_n^{a_n}}{(2\pi)^{k/2} |V_n|^{1/2} \Gamma(a_n)} \int_0^\infty (\sigma^2)^{-m-1} \exp \left\{ -\frac{\lambda}{\sigma^2} \right\} d\sigma^2
 \end{aligned}$$

donde $m = a_n + k/2$ y $\lambda = b_n + \frac{1}{2} (\beta - \beta_n)^\top V_n^{-1} (\beta - \beta_n)$,

$$\begin{aligned}
 &= \frac{b_n^{a_n}}{(2\pi)^{k/2} |V_n|^{1/2} \Gamma(a_n)} \int_0^\infty (\sigma^2)^{-(m+1)} \exp \left\{ -\frac{\lambda}{\sigma^2} \right\} d\sigma^2 \\
 &= \frac{b_n^{a_n}}{(2\pi)^{k/2} |V_n|^{1/2} \Gamma(a_n)} \times \frac{\Gamma(m)}{\lambda^m}
 \end{aligned}$$

usando la función de densidad gamma, $\int_0^\infty x^{-(\alpha+1)} e^{-\beta/x} dx = \frac{\Gamma(\alpha)}{\beta^\alpha}$ con $\alpha = m, \beta = \lambda$,

$$\begin{aligned}
 &= \frac{b_n^{a_n}}{(2\pi)^{k/2} |V_n|^{1/2} \Gamma(a_n)} \times \frac{\Gamma(a_n + k/2)}{[b_n + \frac{1}{2} (\beta - \beta_n)^\top V_n^{-1} (\beta - \beta_n)]^{a_n+k/2}} \\
 &= \frac{\Gamma(a_n + k/2)}{\Gamma(a_n)} \frac{b_n^{a_n}}{(2\pi)^{k/2} |V_n|^{1/2}} \left[b_n + \frac{1}{2} (\beta - \beta_n)^\top V_n^{-1} (\beta - \beta_n) \right]^{-(a_n+k/2)} \\
 &= \frac{\Gamma(a_n + k/2)}{\Gamma(a_n)} \frac{1}{(2\pi)^{k/2} |V_n|^{1/2} b_n^{-a_n}} \left[b_n \left(1 + \frac{1}{2b_n} (\beta - \beta_n)^\top V_n^{-1} (\beta - \beta_n) \right) \right]^{-(a_n+k/2)} \\
 &= \frac{\Gamma(a_n + k/2)}{\Gamma(a_n)} \frac{1}{(2\pi)^{k/2} |V_n|^{1/2} b_n^{-k/2}} \left[1 + \frac{1}{2b_n} (\beta - \beta_n)^\top V_n^{-1} (\beta - \beta_n) \right]^{-(a_n+k/2)} \\
 &= \frac{\Gamma\left(\frac{2a_n+k}{2}\right)}{\Gamma\left(\frac{2a_n}{2}\right) (2a_n\pi)^{k/2} \left| \frac{b_n}{a_n} V_n \right|^{1/2}} \left[1 + \frac{1}{2a_n} (\beta - \beta_n)^\top \left(\frac{b_n}{a_n} V_n \right)^{-1} (\beta - \beta_n) \right]^{-(2a_n+k)/2}
 \end{aligned}$$

La expresión anterior corresponde a la función de densidad de una distribución t de Student multivariada con $2a_n$ grados de libertad, localización β_n y matriz de escala $\frac{a_n}{b_n} V_n$.



Ejercicio

3 Conexión con regularización

1. Regresión Ridge: Muestre que si se toma un prior Normal isotrópico

$$\beta \sim \mathcal{N}(0, \tau^2 I)$$

el estimador de máxima a posteriori (MAP) es equivalente a la regresión Ridge:

$$\hat{\beta}_{\text{MAP}} = \arg \min_{\beta} \|y - X\beta\|^2 + \lambda \|\beta\|^2, \quad \lambda = \sigma^2 / \tau^2$$

Solución:

Sean $p(\mathbf{Y} | \beta)$ la función de densidad de probabilidad de \mathbf{Y} dada β la cual es una normal multivariada con media $X\beta$ y varianza $\sigma^2 I_n$, y $p(\beta)$ la función de densidad de probabilidad de β la cual es una normal multivariada con media $\mathbf{0}$ y varianza $\tau^2 I_p$. Observe que si la función de densidad de los datos se le quitan las constantes, se tiene que esta es proporcional a,

$$\begin{aligned} p(\mathbf{Y} | \beta) &\propto \exp\left(-\frac{1}{2\sigma^2} \|\mathbf{Y} - X\beta\|^2\right) \\ &= \exp\left(-\frac{1}{2\sigma^2} (\mathbf{Y} - X\beta)^\top (\mathbf{Y} - X\beta)\right) \\ &= \exp\left(-\frac{1}{2\sigma^2} (\mathbf{Y}^\top \mathbf{Y} - 2\beta^\top X^\top \mathbf{Y} + \beta^\top X^\top X \beta)\right) \end{aligned}$$

Del mismo modo, se tiene la distribución a priori es proporcional a,

$$p(\beta) \propto \exp\left(-\frac{1}{2\tau^2} \beta^\top \beta\right).$$

De lo anterior se sigue la distribución aposterior es proporcional a,

$$\begin{aligned} p(\beta | \mathbf{Y}) &\propto p(\mathbf{Y} | \beta) \cdot p(\beta) \\ &\propto \exp\left(-\frac{1}{2\sigma^2} (\mathbf{Y}^\top \mathbf{Y} - 2\beta^\top X^\top \mathbf{Y} + \beta^\top X^\top X \beta) - \frac{1}{2\tau^2} \beta^\top \beta\right) \\ &= \exp\left(-\frac{1}{2\sigma^2} \mathbf{Y}^\top \mathbf{Y} + \frac{1}{\sigma^2} \beta^\top X^\top \mathbf{Y} - \frac{1}{2\sigma^2} \beta^\top X^\top X \beta - \frac{1}{2\tau^2} \beta^\top \beta\right) \\ &\propto \exp\left(\beta^\top \left(\frac{X^\top \mathbf{Y}}{\sigma^2}\right) - \frac{1}{2} \beta^\top \left(\frac{X^\top X}{\sigma^2} + \frac{I_p}{\tau^2}\right) \beta\right) \end{aligned}$$

Si se define a

$$\begin{aligned} \Sigma^{-1} &= \frac{X^\top X}{\sigma^2} + \frac{I_p}{\tau^2} \\ \mu &= \Sigma \left(\frac{X^\top \mathbf{Y}}{\sigma^2} \right) \end{aligned}$$

se tiene que la expresión anterior se puede reescribir como,

$$\begin{aligned} p(\beta | \mathbf{Y}) &\propto \exp\left(-\frac{1}{2} \beta^\top \Sigma^{-1} \beta + \beta^\top \Sigma^{-1} \mu\right) \\ &\propto \exp\left(-\frac{1}{2} (\beta - \mu)^\top \Sigma^{-1} (\beta - \mu)\right) \end{aligned}$$

Observe que la expresión anterior corresponde a el kernel de una distribución normal multivariada con media $\boldsymbol{\mu}$ y varianza Σ . De aquí, observe que la media explícita de la distribución a posterior de $\boldsymbol{\beta}$ está dada por,

$$\begin{aligned}\boldsymbol{\mu} &= \left(\frac{X^\top X}{\sigma^2} + \frac{I_p}{\tau^2} \right)^{-1} \frac{X^\top \mathbf{Y}}{\sigma^2} \\ &= \left(X^\top X + \frac{\sigma^2}{\tau^2} I_p \right)^{-1} X^\top \mathbf{Y},\end{aligned}$$

que coincide con el estimador Ridge $\hat{\beta}$. Observe que en este caso, la relación entre α, σ^2 y τ^2 es

$$\alpha = \frac{\sigma^2}{\tau^2}$$

la penalización dependerá de la discrepancia que hay entre la varianza a priori y la varianza de los datos.

Ejercicio

2. Regresión Lasso: Muestre que si en lugar de un prior Normal se utiliza un prior Laplace (doble-exponencial)

$$p(\beta_j) \propto \exp(-\lambda |\beta_j|),$$

el estimador MAP corresponde a la regresión Lasso:

$$\hat{\beta}_{\text{MAP}} = \arg \min_{\beta} \|y - X\beta\|^2 + \lambda \|\beta\|_1$$

Solución:

En este caso, considere el modelo regresión lineal dado por, $y = X\beta + \epsilon$ con errores $\epsilon \sim N(0, \sigma^2 I)$, la verosimilitud es,

$$p(y|X, \beta) \propto \exp\left(-\frac{1}{2\sigma^2} \|y - X\beta\|^2\right).$$

Además, considere una distribución apriori para β dada por,

$$p(\beta|\lambda) = \prod_{j=1}^p \frac{\lambda}{2} \exp(-\lambda |\beta_j|) \propto \exp(-\lambda \|\beta\|_1).$$

Una vez que se tiene definida la función de verosimilitud y la distribución a priori, se puede obtener la distribución a posterior dada por,

$$\begin{aligned} p(\beta | y) &\propto p(y | \beta) \cdot p(\beta) \\ &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - x_i^T \beta)^2}{2\sigma^2}\right) \cdot \prod_{j=1}^p \frac{\lambda}{2} \exp(-\lambda |\beta_j|) \\ &\propto \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - x_i^T \beta)^2\right) \cdot \exp\left(-\lambda \sum_{j=1}^p |\beta_j|\right) \\ &= \exp\left(-\frac{1}{2\sigma^2} \|y - X\beta\|^2 - \lambda \sum_{j=1}^p |\beta_j|\right) \\ &= \exp\left(-\frac{1}{2\sigma^2} \|y - X\beta\|^2 - \lambda \|\beta\|_1\right) \\ p(\beta|y) &\propto \exp\left(-\frac{1}{2\sigma^2} \|y - X\beta\|^2 - \lambda \sum_{j=1}^p |\beta_j|\right). \end{aligned}$$

Por último, observe que el estimador MAP (Maximum A Posteriori) se obtiene maximizando la distribución posterior,

$$\hat{\beta}_{\text{MAP}} = \arg \max_{\beta} p(\beta|y) = \arg \max_{\beta} p(y|\beta)p(\beta),$$

además, note que maximizar $p(\beta|y)$ es equivalente a minimizar el negativo del log-posterior,

$$\hat{\beta}_{\text{MAP}} = \arg \min_{\beta} \left\{ \frac{1}{2\sigma^2} \|y - X\beta\|^2 + \lambda \sum_{j=1}^p |\beta_j| \right\}.$$

Multiplicando por $2\sigma^2$ y definiendo $\lambda' = 2\sigma^2\lambda$,

$$\hat{\beta}_{\text{MAP}} = \arg \min_{\beta} \{ \|y - X\beta\|^2 + \lambda' \|\beta\|_1 \}$$

que es exactamente la formulación de la regresión Lasso.



Ejercicio

4 Extensiones: errores no normales

1. Modelos alternativos: Proponga un modelo de regresión donde el error ε no siga una distribución Normal. Ejemplos:

- $\varepsilon \sim \text{Laplace}(0, b)$ (robusto a outliers).
- $\varepsilon \sim \text{Student-}t(\nu)$ (colas pesadas).

2. Consecuencias metodológicas: Explique cuáles serían las consecuencias sobre:

- La forma de la verosimilitud.
- La existencia o no de priors conjugados.
- Los métodos de inferencia requeridos (MCMC, aproximación variacional, etc.).

Solución:

Para realizar este análisis, considere un modelo de regresión lineal dado por, dado por, $y = X\beta + \varepsilon$ con errores $\varepsilon \sim \text{Student-}t(\nu)$. En este caso la verosimilitud toma la forma,

$$\begin{aligned} p(y|X, \beta, \sigma^2, \nu) &= \prod_{i=1}^n \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi}\Gamma\left(\frac{\nu}{2}\right)} \left(1 + \frac{(y_i - x_i^\top \beta)^2}{\nu\sigma^2}\right)^{-\frac{\nu+1}{2}} \\ &= \left[\frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi}\Gamma\left(\frac{\nu}{2}\right)} \right]^n \prod_{i=1}^n \left(1 + \frac{(y_i - x_i^\top \beta)^2}{\nu\sigma^2}\right)^{-\frac{\nu+1}{2}} \end{aligned}$$

Donde,

- $\nu > 0$ son los grados de libertad
- σ^2 es el parámetro de escala
- $\Gamma(\cdot)$ es la función Gamma
- x_i^\top es la fila i -ésima de la matriz de diseño X .

Observe que esta distribución tiene colas más pesadas, lo que lleva a que residuos de mayor tamaño tengan mayor probabilidad, esto produce que los parámetros no se vean tan afectados por outliers y se tengan estimaciones más robustas.

Se sabe que para una verosimilitud de este tipo, no hay distribuciones a priori tales que se pueda tener un modelo conjugado con esta verosimilitud. Sin embargo, se puede recurrir a modelos semi conjugados, los cuales pueden facilitar las cuentas y la implementación de algoritmos de muestreo. Al no poder llegar a una expresión cerrada de la distribución posterior, se debe recurrir a otros métodos de inferencia. Usualmente se utiliza MCMC, como Gibbs sampling o Metropolis Hasting. Particularmente, si se plantea,

$$\varepsilon_i \mid \lambda_i = l \sim \mathcal{N}(0, \sigma^2/l), \quad \lambda_i \sim \text{Gamma}\left(\frac{\nu}{2}, \frac{\nu}{2}\right)$$

, entonces se puede obtener la distribución t de Student con ν grados de libertad y escala σ^2 , marginalizando sobre λ_i . A partir de esto, condicionando a λ, β sigue una distribución normal.

En este caso en particular, se puede implementar un muestreo de Gibbs, muestreando a β a partir de la normal condicional, σ^2 a partir de una gamma inversa (como en el caso usual) y a λ_i a partir de la gamma propuesta, ν se puede muestrear a partir de un algoritmo Metrópolis Hasting.